

实验物理中的统计方法

第 1 章基本概念

1. 考虑某样本空间 S 以及给定子空间 B , 并假设 $P(B) > 0$. 证明条件概率

$$P(A|B) = \frac{P(A \cap B)}{P(B)}.$$

满足概率的公理。

解答:

对固定的 B 且 $P(B) > 0$, 定义 $P_B(A) = P(A|B) = P(A \cap B)/P(B)$. 验证概率公理:

- (1) 非负性: $P(A \cap B) \geq 0$, 故 $P_B(A) \geq 0$.
- (2) 归一性: $P_B(S) = P(S \cap B)/P(B) = P(B)/P(B) = 1$.
- (3) 可列可加性: 若 A_i 两两不交, 则 $(A_i \cap B)$ 也两两不交, 故

$$P_B\left(\bigcup_i A_i\right) = \frac{P(\bigcup_i (A_i \cap B))}{P(B)} = \frac{\sum_i P(A_i \cap B)}{P(B)} = \sum_i P_B(A_i).$$

因此条件概率满足概率公理。

2. 证明

$$P(A \cup B) = P(A) + P(B) - P(A \cap B).$$

(提示: 将 $A \cup B$ 表示成 3 个不相交的子集的并。)

解答:

把 $A \cup B$ 分成三个互不相交的部分:

$$A \cup B = (A \setminus B) \cup (B \setminus A) \cup (A \cap B).$$

于是

$$P(A \cup B) = P(A \setminus B) + P(B \setminus A) + P(A \cap B).$$

又

$$P(A) = P(A \setminus B) + P(A \cap B), \quad P(B) = P(B \setminus A) + P(A \cap B),$$

所以

$$P(A \cup B) = P(A) + P(B) - P(A \cap B).$$

3. 某粒子束流包含 10^{-4} 的电子, 其余为光子。粒子通过某双层探测器, 可能在两层都给出信号, 也可能只有一层给出信号或者没有任何信号。电子 (e) 和光子 (γ) 在穿过该双层探测器给出 0, 1 或 2 个信号的概率如下

$$\begin{aligned} P(0|e) &= 0.001, & P(0|\gamma) &= 0.99899, \\ P(1|e) &= 0.01, & P(1|\gamma) &= 0.001, \\ P(2|e) &= 0.989, & P(2|\gamma) &= 10^{-5}. \end{aligned}$$

- (1) 如果只有一层给出信号, 该粒子为光子的概率是多少?
 (2) 如果两层都给出了信号, 该粒子为电子的概率是多少?

解答:

设先验概率 $P(e) = 10^{-4}$, $P(\gamma) = 1 - 10^{-4} = 0.9999$ 。

- (1) 只有一层给出信号时, 用 Bayes 公式:

$$P(\gamma|1) = \frac{P(1|\gamma)P(\gamma)}{P(1|e)P(e) + P(1|\gamma)P(\gamma)}.$$

代入数值:

$$P(\gamma|1) = \frac{0.001 \times 0.9999}{0.01 \times 10^{-4} + 0.001 \times 0.9999} \approx 0.9990.$$

- (2) 两层都给出信号时:

$$P(e|2) = \frac{P(2|e)P(e)}{P(2|e)P(e) + P(2|\gamma)P(\gamma)} = \frac{0.989 \times 10^{-4}}{0.989 \times 10^{-4} + 10^{-5} \times 0.9999} \approx 0.9082.$$

4. 假设随机变量 x 的概率密度函数为 $f(x)$ 。证明 $y = x^2$ 的概率密度函数为

$$g(y) = \frac{1}{2\sqrt{y}}f(\sqrt{y}) + \frac{1}{2\sqrt{y}}f(-\sqrt{y}).$$

解答:

令 $y = x^2$ 。当 $y > 0$ 时, 反解有两个分支 $x = \sqrt{y}$ 和 $x = -\sqrt{y}$, 且

$$\left| \frac{dx}{dy} \right| = \frac{1}{2\sqrt{y}}.$$

变量变换公式给出

$$g(y) = f(\sqrt{y})\frac{1}{2\sqrt{y}} + f(-\sqrt{y})\frac{1}{2\sqrt{y}}, \quad y > 0.$$

即

$$g(y) = \frac{1}{2\sqrt{y}}f(\sqrt{y}) + \frac{1}{2\sqrt{y}}f(-\sqrt{y}).$$

5. 假设两个独立的随机变量 x 和 y 都服从 0 到 1 之间的均匀分布, 即概率密度函数 $g(x)$ 为

$$g(x) = \begin{cases} 1, & 0 < x < 1, \\ 0, & \text{其它.} \end{cases}$$

概率密度函数 $h(y)$ 与 $g(x)$ 类似。

- (1) 利用 Statistical Data Analysis 中的 (1.35) 式, 证明 $z = xy$ 的概率密度函数 $f(z)$ 为

$$f(z) = \begin{cases} -\log z, & 0 < z < 1, \\ 0, & \text{其它.} \end{cases}$$

- (b) 利用 Statistical Data Analysis 的 (1.37) 和 (1.38) 式, 通过另外定义一个函数 $u = x$, 求 $z = xy$ 的概率密度函数。首先求 z 和 u 的联合概率密度函数, 然后对 u 进行积分求出 z 的概率密度函数。

(c) 证明 z 的累积分布为

$$F(z) = z(1 - \log z).$$

解答:

(1) 对 $z = xy$, 且 $x, y \sim U(0, 1)$ 独立。固定 x , 由 $y = z/x$, 需要 $0 < z/x < 1$, 即 $z < x < 1$ 。因此

$$f_Z(z) = \int_z^1 1 \cdot 1 \cdot \frac{1}{x} dx = -\log z, \quad 0 < z < 1.$$

其它 z 区间密度为 0。

(2) 令 $u = x$, $z = xy$, 则 $x = u$, $y = z/u$ 。Jacobian 为

$$\left| \frac{\partial(x, y)}{\partial(z, u)} \right| = \begin{vmatrix} 0 & 1 \\ 1/u & -z/u^2 \end{vmatrix} = \frac{1}{u}.$$

由于 $0 < u < 1$ 且 $0 < z/u < 1$, 有 $z < u < 1$ 。所以联合密度

$$f_{Z,U}(z, u) = \frac{1}{u}, \quad 0 < z < u < 1.$$

积分掉 u :

$$f_Z(z) = \int_z^1 \frac{1}{u} du = -\log z.$$

(3) 累积分布为

$$F(z) = P(XY \leq z) = \int_0^z [-\log t] dt = z(1 - \log z), \quad 0 < z < 1.$$

6. 考虑随机变量 x 与常数 α 和 β 。证明

$$E[\alpha x + \beta] = \alpha E[x] + \beta,$$

$$V[\alpha x + \beta] = \alpha^2 V[x].$$

解答:

利用期待值线性性:

$$E[\alpha x + \beta] = \alpha E[x] + \beta.$$

方差为

$$V[\alpha x + \beta] = E[(\alpha x + \beta - \alpha E[x] - \beta)^2] = E[\alpha^2 (x - E[x])^2] = \alpha^2 V[x].$$

7. 考虑两个随机变量 x 和 y 。

(1) 证明 $\alpha x + y$ 的方差为

$$\begin{aligned} V[\alpha x + y] &= \alpha^2 V[x] + V[y] + 2\alpha \operatorname{cov}[x, y] \\ &= \alpha^2 V[x] + V[y] + 2\alpha \rho \sigma_x \sigma_y. \end{aligned}$$

其中 α 为任意常数, $\sigma_x^2 = V[x]$, $\sigma_y^2 = V[y]$, 关联系数 $\rho = \operatorname{cov}[x, y]/(\sigma_x \sigma_y)$ 。

(2) 利用 (a) 的结果, 证明关联系数总是位于区间 $-1 \leq \rho \leq 1$ 。(利用 $V[\alpha x + y]$ 的方差总是大于或等于零。)

解答：

(1) 由方差定义：

$$\begin{aligned}
 V[\alpha x + y] &= E[(\alpha(x - E[x]) + (y - E[y]))^2] \\
 &= \alpha^2 V[x] + V[y] + 2\alpha \operatorname{cov}[x, y] \\
 &= \alpha^2 \sigma_x^2 + \sigma_y^2 + 2\alpha \rho \sigma_x \sigma_y.
 \end{aligned}$$

(2) 因为方差非负，对任意 α ，二次函数

$$\alpha^2 \sigma_x^2 + 2\alpha \rho \sigma_x \sigma_y + \sigma_y^2 \geq 0.$$

其判别式必须不大于 0：

$$(2\rho\sigma_x\sigma_y)^2 - 4\sigma_x^2\sigma_y^2 \leq 0.$$

若 $\sigma_x\sigma_y > 0$ ，得到 $\rho^2 \leq 1$ ，即 $-1 \leq \rho \leq 1$ 。若某个方差为零，相关系数退化，结论可由极限理解。

8. 假设随机变量 $x = (x_1, \dots, x_n)^T$ 用联合概率密度函数 $f(x)$ 描述，而变量 $y = (y_1, \dots, y_n)^T$ 由下面的线性变换定义

$$y_i = \sum_{j=1}^n A_{ij} x_j.$$

假设反变换 $x = A^{-1}y$ 存在。(1) 证明 y 的联合概率密度函数为

$$g(y) = f(A^{-1}y) |\det(A^{-1})|.$$

(b) 当 A 为正交矩阵，即 $A^{-1} = A^T$ 时，求 $g(y)$ 。**解答：**(1) 线性变换为 $y = Ax$ ，反变换 $x = A^{-1}y$ 。多维变量变换公式给出

$$g(y) = f(A^{-1}y) \left| \det \frac{\partial x}{\partial y} \right| = f(A^{-1}y) |\det(A^{-1})|.$$

(2) 若 A 为正交矩阵，则 $A^{-1} = A^T$ ，且 $|\det(A^{-1})| = 1$ 。因此

$$g(y) = f(A^T y).$$

实验物理中的统计方法

第 2 章常用概率密度函数

1. 考虑 N 个服从多项分布的随机变量 $n = (n_1, \dots, n_N)$, 概率为 $p = (p_1, \dots, p_N)$, 并且总试验次数为 $n_{\text{tot}} = \sum_{i=1}^N n_i$ 。假设变量 k 定义为前 M 个 n_i 之和,

$$k = \sum_{i=1}^M n_i, \quad M \leq N.$$

利用误差传递以及多项分布的协方差

$$\text{cov}[n_i, n_j] = \delta_{ij} n_{\text{tot}} p_i (1 - p_i) + (\delta_{ij} - 1) p_i p_j n_{\text{tot}},$$

求 k 的方差。证明该方差等于 $p = \sum_{i=1}^M p_i$ 并且总试验次数为 n_{tot} 的二项分布的方差。

解答:

有

$$k = \sum_{i=1}^M n_i.$$

因此

$$V[k] = \sum_{i=1}^M \sum_{j=1}^M \text{cov}(n_i, n_j).$$

多项分布中

$$\text{Var}(n_i) = n_{\text{tot}} p_i (1 - p_i), \quad \text{cov}(n_i, n_j) = -n_{\text{tot}} p_i p_j \quad (i \neq j).$$

所以

$$\begin{aligned} V[k] &= n_{\text{tot}} \sum_{i=1}^M p_i (1 - p_i) - 2n_{\text{tot}} \sum_{i < j} p_i p_j \\ &= n_{\text{tot}} \left[\sum_i p_i - \left(\sum_i p_i \right)^2 \right]. \end{aligned}$$

令 $p = \sum_{i=1}^M p_i$, 则

$$V[k] = n_{\text{tot}} p (1 - p),$$

正是参数为 n_{tot}, p 的二项分布方差。

2. 假设随机变量 x 均匀分布于区间 $[\alpha, \beta]$, $\alpha, \beta > 0$ 。求 $1/x$ 的期待值, 并将结果与 $1/\text{E}[x]$ 进行比较, 取 $\alpha = 1, \beta = 2$ 。

解答:

若 $x \sim U[\alpha, \beta]$, 则

$$\text{E} \left[\frac{1}{x} \right] = \frac{1}{\beta - \alpha} \int_{\alpha}^{\beta} \frac{1}{x} dx = \frac{\log \beta - \log \alpha}{\beta - \alpha}.$$

而

$$\frac{1}{E[x]} = \frac{2}{\alpha + \beta}.$$

取 $\alpha = 1, \beta = 2$,

$$E[1/x] = \log 2 \approx 0.6931, \quad 1/E[x] = 2/3 \approx 0.6667.$$

两者不相等, 这是非线性函数期待值一般不等于函数作用在期待值上的结果。

3. 考虑指数分布

$$f(x; \xi) = \frac{1}{\xi} e^{-x/\xi}, \quad x \geq 0.$$

(1) 证明对应的累积分布函数为

$$F(x) = 1 - e^{-x/\xi}, \quad x \geq 0.$$

(2) 证明给定 $x > x_0$ 时 x 处于 x_0 与 $x_0 + x'$ 之间的条件概率等于 x 小于 x' 的概率 (非条件概率), 即

$$P(x \leq x_0 + x' | x \geq x_0) = P(x \leq x').$$

(3) 产生于大气上层的宇宙线 μ 子进入海平面的探测器, 其中的一部分在探测器中停止并衰变。进入探测器与衰变的时间差 t 服从指数分布, t 的均值等于 μ 子的平均寿命 (近似为 $2.2 \mu\text{s}$)。解释为什么 μ 子进入探测器前存活的时间对确定平均寿命没有影响。

解答:

(1) 对指数密度积分:

$$F(x) = \int_0^x \frac{1}{\xi} e^{-t/\xi} dt = 1 - e^{-x/\xi}, \quad x \geq 0.$$

(2) 对 $x_0, x' > 0$,

$$\begin{aligned} P(x \leq x_0 + x' | x \geq x_0) &= \frac{P(x_0 \leq x \leq x_0 + x')}{P(x \geq x_0)} \\ &= \frac{e^{-x_0/\xi} - e^{-(x_0+x')/\xi}}{e^{-x_0/\xi}} \\ &= 1 - e^{-x'/\xi} = P(x \leq x'). \end{aligned}$$

这就是指数分布的无记忆性。

(3) μ 子进入探测器前已经存活了某段时间, 相当于已知 $t \geq t_0$ 。由于指数分布无记忆, 进入前已经存活多久不改变之后剩余寿命的分布。因此用进入探测器到衰变的时间差仍可估计平均寿命。

4. 假设 y 服从均值为 μ , 方差为 σ^2 的高斯分布。

(1) 证明

$$x = \frac{y - \mu}{\sigma}$$

服从标准高斯分布 $\phi(x)$ (即, 均值为零, 方差为 1)。

(2) 证明累积分布函数 $F(y)$ 与 $\Phi(x)$ 相等, 即

$$F(y) = \Phi\left(\frac{y - \mu}{\sigma}\right).$$

解答:

(1) 令 $x = (y - \mu)/\sigma$, 即 $y = \mu + \sigma x$, $\left|\frac{dy}{dx}\right| = \sigma$ 。于是

$$f_X(x) = f_Y(\mu + \sigma x)\sigma = \frac{1}{\sqrt{2\pi}}e^{-x^2/2},$$

即标准高斯分布。

(2) 因为 $y \leq y_0$ 等价于 $x \leq (y_0 - \mu)/\sigma$, 故

$$F_Y(y) = \Phi\left(\frac{y - \mu}{\sigma}\right).$$

5.

(1) 证明, 如果 y 服从均值为 μ 、方差为 σ^2 的高斯分布, 则 $x = e^y$ 服从对数正态分布,

$$f(x; \mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \frac{1}{x} \exp\left[-\frac{(\log x - \mu)^2}{2\sigma^2}\right].$$

(2) 通过积分

$$\begin{aligned} E[x] &= \int x f(x; \mu, \sigma^2) dx, \\ V[x] &= \int (x - E[x])^2 f(x; \mu, \sigma^2) dx. \end{aligned}$$

求 x 的均值与方差。

(3) 将 (b) 中求得的方差与通过误差传递 ($V[y] = \sigma^2$) 得到的近似结果进行比较。在什么条件下误差传递近似成立? (注意 y 是无量纲的, 因而 σ^2 也是无量纲的。)

解答:

(1) $x = e^y$, 反变换 $y = \log x$, Jacobian 为 $\left|\frac{dy}{dx}\right| = 1/x$ 。所以

$$f_X(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \frac{1}{x} \exp\left[-\frac{(\log x - \mu)^2}{2\sigma^2}\right], \quad x > 0.$$

(2) 由于 $x = e^y$, 且 $y \sim N(\mu, \sigma^2)$, 高斯矩母函数给出

$$E[x] = E[e^y] = e^{\mu + \sigma^2/2}.$$

又

$$E[x^2] = E[e^{2y}] = e^{2\mu + 2\sigma^2},$$

因此

$$V[x] = e^{2\mu + 2\sigma^2} - e^{2\mu + \sigma^2} = e^{2\mu + \sigma^2}(e^{\sigma^2} - 1).$$

(3) 误差传递近似给出

$$V[x] \approx \left(\frac{dx}{dy} \bigg|_{\mu} \right)^2 V[y] = e^{2\mu} \sigma^2.$$

精确结果在 $\sigma^2 \ll 1$ 时

$$e^{2\mu+\sigma^2}(e^{\sigma^2}-1) \approx e^{2\mu}\sigma^2,$$

所以误差传递近似在 y 的相对波动较小, 即 $\sigma^2 \ll 1$ 时成立。

6. 证明自由度为 n 的 χ^2 分布的累积分布函数可以表示为

$$F_{\chi^2}(x; n) = P\left(\frac{x}{2}, \frac{n}{2}\right),$$

其中 P 为不完全伽马函数 (incomplete gamma function)

$$P(x, n) = \frac{1}{\Gamma(n)} \int_0^x e^{-t} t^{n-1} dt.$$

解答:

自由度为 n 的 χ^2 密度为

$$f(t; n) = \frac{1}{2^{n/2} \Gamma(n/2)} t^{n/2-1} e^{-t/2}, \quad t > 0.$$

累积分布

$$F_{\chi^2}(x; n) = \int_0^x f(t; n) dt.$$

令 $u = t/2$, $dt = 2 du$, 则

$$F_{\chi^2}(x; n) = \frac{1}{\Gamma(n/2)} \int_0^{x/2} e^{-u} u^{n/2-1} du = P\left(\frac{x}{2}, \frac{n}{2}\right).$$


实验物理中的统计方法

第 3 章蒙特卡罗方法

1. 写一段小程序，利用 ROOT 中的随机数产生子产生 10^4 个 $(0, 1]$ 之间均匀分布的随机数，将结果画到直方图中（分 100 个区间）。

解答：

可按如下步骤实现：产生 10000 个均匀随机数，每个随机数填入区间为 $[0, 1]$ 、分箱数为 100 的直方图。ROOT 中可用 `gRandom->Rndm()` 或 `TRandom3::Uniform(0,1)` 产生 $[0, 1)$ 上的均匀随机数；端点取 $(0, 1]$ 或 $[0, 1)$ 对连续分布没有实际影响。



Python 复现实验生成的均匀分布直方图；虚线为每箱期望计数 100。

理论上

$$E[X] = \int_0^1 x \, dx = \frac{1}{2}, \quad V[X] = \int_0^1 x^2 \, dx - \left(\frac{1}{2}\right)^2 = \frac{1}{12}.$$

一次典型模拟可能得到

$$\bar{x} \simeq 0.497, \quad s^2 \simeq 0.0830,$$

与理论值 0.5 和 $1/12 = 0.08333$ 相符；由于样本量有限，具体数值会随随机数种子波动。

2. 修改本章第 1 题中的直方图，使其只有 5 个区间，事例数 $N = 100$ 。产生的直方图可以看做对矢量 $(n_1, \dots, n_5)$ 的观测，该矢量满足参数 $N = 100$, $p_i = 0.2$ ($i = 1, \dots, 5$) 的多项分布。

- (1) 将上面的程序代码放到循环中产生直方图，重复该 MC 实验 100 次，每次用不同的随机数种子。只要保证每次实验程序不中断，程序在下一实验（即下一个循环）时自动更新种子。定义一个直方图，将每次实验第 i 个区间（比如 $i = 3$ ）的值填充其中。这应该服从均值为 $Np_i = 20$ ，标准偏差为 $\sqrt{Np_i(1-p_i)} = 4$ 的二项分布。
- (2) 为任意两个区间的值 n_i 和 n_j 作出散点图（二维直方图）。其协方差的理论值为 $\text{cov}[n_i, n_j] = -Np_i p_j = -4$ ，或者说关联系数 $\rho = -4/4^2 = -0.25$ 。

解答：

每次实验中把 $N = 100$ 个均匀随机数填入 5 个等宽箱。由于每个箱的概率为 $p_i = 0.2$ ，单个箱计数满

足边缘二项分布


$$n_i \sim \text{Binom}(100, 0.2), \quad E[n_i] = 20, \quad \sigma_{n_i} = \sqrt{100 \cdot 0.2 \cdot 0.8} = 4.$$

任意两个不同箱的计数满足多项分布协方差


$$\text{cov}(n_i, n_j) = -Np_i p_j = -100 \cdot 0.2 \cdot 0.2 = -4, \quad \rho_{ij} = \frac{-4}{4 \cdot 4} = -0.25.$$

因此应把 100 次重复实验得到的某个箱计数（如 n_3 ）再填入一个新直方图，其中心应在 20 附近，宽度约为 4。对 (n_i, n_j) 作二维散点图时，点云应表现出负相关：一个箱中的事件数偏多时，其它箱的总数被固定条件压低。

若只重复 100 次，样本协方差和相关系数的统计波动仍会较大；例如得到 $\text{corr}(n_1, n_2) = -0.14$ 并不奇怪。若把重复次数提高到 10^4 或更多，样本均值、标准差和相关系数会更稳定地趋近于上面的理论值。



10^4 次重复实验中单个箱计数的经验分布及二项分布理论曲线。



两个不同箱计数的散点图；总数固定导致负相关。

3. 考虑锯齿分布

$$f(x) = \begin{cases} \frac{2x}{x_{\max}^2}, & 0 < x < x_{\max}, \\ 0, & \text{其它.} \end{cases}$$

- (1) 参考课本 3.2 节, 利用变换方法寻找函数 $x(r)$, 以产生服从 $f(x)$ 的随机数。用程序实现该方法, 并生成一个直方图。(可以取 $x_{\max} = 1$ 。)
- (2) 参考课本 3.3 节, 编写一段程序, 利用舍选法产生服从锯齿分布的随机数。画出相应的直方图。

解答:

题设密度为

$$f(x) = \frac{2x}{x_{\max}^2}, \quad 0 < x < x_{\max}.$$

- (1) 反变换法
分布函数为

$$F(x) = \int_0^x \frac{2t}{x_{\max}^2} dt = \frac{x^2}{x_{\max}^2}.$$

令 $r \sim U(0,1)$, 取 $r = F(x)$, 得到

$$x(r) = x_{\max} \sqrt{r}.$$

因此程序中每产生一个均匀随机数 r , 填入 $x = x_{\max} \sqrt{r}$ 即可。直方图应随 x 线性上升。

- (2) 舍选法
取建议分布

$$g(x) = \frac{1}{x_{\max}}, \quad 0 < x < x_{\max}.$$


则

$$\frac{f(x)}{g(x)} = \frac{2x}{x_{\max}} \leq 2,$$

可取 $M = 2$ 。算法为: 先在 $(0, x_{\max})$ 上均匀产生候选值 x , 再产生 $u \sim U(0,1)$, 若

$$u < \frac{f(x)}{Mg(x)} = \frac{x}{x_{\max}}$$

则接受该 x , 否则重抽。接受率为 $1/M = 1/2$ 。



反变换法和舍选法产生的样本直方图; 实线为理论密度 $f(x) = 2x$ 。

4. 该练习的目的是产生服从高斯分布的随机数。有很多算法可以产生高斯分布，一个最简单的适合教学目的算法基于中心极限定理：当 n 很大时， n 个随机数之和趋向于高斯分布，只要其中任何一项不占绝对份额（参考课本第 10 章）。

(1) 假设 x 均匀分布于 $[0, 1]$ ，考虑 n 个独立随机变量 x 之和，

$$y = \sum_{i=1}^n x_i.$$

证明 y 的期待值为 $n/2$ ，方差为 $n/12$ 。并证明变量 z

$$z = \frac{\sum_{i=1}^n x_i - n/2}{\sqrt{n/12}}$$

均值为零，标准偏差为 1。

(2) 写一段小程序产生 (a) 中定义的变量 z ， n 可以为任意值。分别取 $n = 1, \dots, 20$ ，生成直方图，每个直方图包含 10^4 个 z 的值。何时 z 的分布近似为高斯分布？作为简单的高斯分布产生子，可以取 $n = 12$ 。评论此算法的局限性。选作：对于 $n = 2$ ，推导出 z 的概率密度函数的明显形式。

解答：

设 $x_i \sim U(0, 1)$ 独立同分布，

$$y = \sum_{i=1}^n x_i.$$

因为 $E[x_i] = 1/2$ 、 $V[x_i] = 1/12$ ，独立性给出

$$E[y] = \sum_i E[x_i] = \frac{n}{2}, \quad V[y] = \sum_i V[x_i] = \frac{n}{12}.$$


标准化变量

$$z = \frac{y - n/2}{\sqrt{n/12}}$$

满足

$$E[z] = 0, \quad V[z] = 1.$$

由中心极限定理， n 增大时 z 的分布趋近标准高斯分布。实际作图时， $n = 1$ 仍是均匀分布， $n = 2$ 是三角形分布， $n \approx 10 \sim 12$ 时中心部分已经相当接近高斯。



不同 n 下标准化变量 z 的经验密度； n 增大时逐渐接近标准高斯。

这个算法的局限性是： z 的取值范围有限，

$$-\sqrt{3n} < z < \sqrt{3n},$$

所以它不能正确产生高斯分布的极端尾部；例如 $n = 12$ 时只能产生 $[-6, 6]$ 内的值。此外，尾部形状与真正高斯尾部仍有系统差异。

选作：当 $n = 2$ 时， $y = x_1 + x_2$ 的密度为

$$f_Y(y) = \begin{cases} y, & 0 < y < 1, \\ 2 - y, & 1 < y < 2, \\ 0, & \text{其它}, \end{cases}$$

而 $z = (y - 1)/\sqrt{1/6} = \sqrt{6}(y - 1)$ 。故

$$f_Z(z) = \begin{cases} \frac{1 + z/\sqrt{6}}{\sqrt{6}}, & -\sqrt{6} < z < 0, \\ \frac{1 - z/\sqrt{6}}{\sqrt{6}}, & 0 < z < \sqrt{6}, \\ 0, & \text{其它}. \end{cases}$$

5. 变量 t 服从均值 $\tau = 1$ 的指数分布， x 服从均值 $\mu = 0$ 、标准偏差 $\sigma = 0.5$ 的高斯分布。写一段 MC 程序，产生变量

$$y = t + x.$$

这里 t 可以表示不稳定粒子的真实衰变时间， x 表示测量误差，所以 y 表示测量到的衰变时间。画出 y 的直方图。修改程序以研究 $\tau \ll \sigma$ 和 $\tau \gg \sigma$ 的情形。

解答：

设 $t \sim \text{Exp}(\tau)$ ，即 $E[t] = \tau$ 、 $V[t] = \tau^2$ ，且 $x \sim N(0, \sigma^2)$ ，二者独立。则

$$y = t + x$$


服从指数分布与高斯分布的卷积，常称为 exGaussian 分布。基本矩为

$$E[y] = E[t] + E[x] = \tau, \quad V[y] = V[t] + V[x] = \tau^2 + \sigma^2.$$

若需要写出解析密度，则

$$f_Y(y) = \frac{1}{2\tau} \exp\left(\frac{\sigma^2}{2\tau^2} - \frac{y}{\tau}\right) \text{erfc}\left(\frac{\sigma^2/\tau - y}{\sqrt{2}\sigma}\right).$$

MC 程序中可先产生 $t = -\tau \log r$ ($r \sim U(0, 1)$)，再产生一个高斯随机数 x ，最后填入 $y = t + x$ 的直方图。



不同 τ/σ 比例下 $y = t + x$ 的模拟分布。

- (1) 当 $\tau \ll \sigma$ 时，测量误差主导，分布中心部分近似高斯，只带很弱的右尾。
- (2) 当 $\tau \sim \sigma$ 时，分布明显右偏，既有高斯展宽又有指数长尾。
- (3) 当 $\tau \gg \sigma$ 时，指数衰变形状主导，高斯误差主要抹平 y 接近零的边界。

6. 考虑服从 Cauchy(Breit-Wigner) 分布的随机变量 x ,

$$f(x) = \frac{1}{\pi} \frac{1}{1+x^2}.$$

- (1) 证明如果 r 均匀分布于 $[0, 1]$, 则

$$x(r) = \tan \left[\pi \left(r - \frac{1}{2} \right) \right]$$

服从 Cauchy 分布。

- (2) 利用 (a) 中的结果，写一段小程序产生 Cauchy 分布的随机数。产生 10^4 个事例并画出直方图。
- (3) 修改 (b) 中的程序，重复进行实验，每次实验 n 个独立的柯西分布数值（如取 $n = 10$ ）。对每个样本，计算样本均值 $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$ 。比较 $\bar{x}$ 的直方图与 x 的原始直方图。（参见第 10 章第 8 题。）

解答：

- (1) 若 $r \sim U(0, 1)$, 令

$$x = \tan \left[\pi \left(r - \frac{1}{2} \right) \right].$$

则

$$r = \frac{1}{2} + \frac{1}{\pi} \arctan x,$$

所以分布函数为

$$F(x) = P(X \leq x) = \frac{1}{2} + \frac{1}{\pi} \arctan x.$$

对 x 求导，得到


$$f(x) = F'(x) = \frac{1}{\pi(1+x^2)},$$

即标准 Cauchy 分布。

- (2) 程序中只需对每个均匀随机数 r 计算上式的 $x(r)$ 并填入直方图。由于 Cauchy 分布有很长的尾部，作图时常把横轴限制在例如 $[-10, 10]$ 或 $[-20, 20]$ ，否则少数极端值会压缩中心区域。
- (3) 对每次实验产生 n 个独立 Cauchy 变量并计算样本均值

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i.$$

由第 10 章的特征函数结论， $\bar{x}$ 仍服从同一个标准 Cauchy 分布；因此其直方图不会像高斯样本均值那样随 n 增大而变窄。这不是数值程序错误，而是因为 Cauchy 分布没有有限的均值和方差，通常的大数定律条件不成立。



单个 Cauchy 变量与 10 个 Cauchy 变量样本均值的直方图；两者服从同一分布。

7. 光电倍增管是可以探测单光子的设备，如图 3.1 所示。




图 3.1: 光电倍增管级联放大示意图。

光子打到光阴极上，有一定的概率发射出一个电子（即光电子）。光电子在电场中向电极（称为打拿极）加速。当光电子撞到第一个打拿极时，光电子可以进一步释放出电子。这些电子又被加速到第二个打拿极，产生更多的电子。该过程一直持续，直到最后一个打拿极产生的电子被收集起来。

进入第 i 个打拿极的每个电子产生的次级电子数目可以看成均值为 ν_i 的泊松变量 n_i ，一般而言，每个打拿极的泊松均值 ν_i 不同。假设光电倍增管有 N 个打拿极，单个入射光电子最终产生的电子数目 n_{out} 的期待值（即光电倍增管的增益）为

$$\nu_{\text{out}} = E[n_{\text{out}}] = \prod_{i=1}^N \nu_i.$$

- (1) 写一段蒙特卡罗程序，用来计算 $N = 6$ 时单个光电子产生的电子数 n_{out} 的分布，对所有打拿极取 $\nu = 3.0$ 。(ROOT 中可以直接调用函数产生泊松分布。)利用你写的程序，重复 $M = 1000$ 次单个光电子事件，从而得到 M 个 n_{out} ，作出这 M 个 n_{out} 值的直方图。(建议直方图分 50 个区间。)通过计算样本均值和样本方差

$$\bar{n}_{\text{out}} = \frac{1}{M} \sum_{i=1}^M n_{\text{out},i}$$

$$s_{\text{out}}^2 = \frac{1}{M-1} \sum_{i=1}^M (n_{\text{out},i} - \bar{n}_{\text{out}})^2$$

以估计均值 ν_{out} 和方差 $V[n_{\text{out}}] = \sigma_{\text{out}}^2$ (样本均值和样本方差详见 Statistical Data Analysis 第 5 章)。将样本均值与 (3.7) 式给出的值进行比较。比较样本方差 (或标准差) 与均值为 ν_{out} 的泊松变量的方差。定性解释为什么 n_{out} 的标准差远大于泊松变量的标准差。

- (2) 我们希望 n_{out} 的标准差尽量小，以便能够尽可能精确地确定初始光电子的数目 (从而可以估计入射光子的数目)。在某些应用中，需要标准差小到可以区分到底是一个还是两个光子，因此希望使相对分辨率 (即标准差与均值的比值) 小于 1。减小方差的一个方法是提高第一个打拿极产生电子数的均值，这可以通过增大电压从而提高入射到打拿极的光电子的能量来实现，也可以通过选取较低功函数的金属 (即提高发射次级电子的概率) 来实现。

修改 (a) 中的程序，增大第一个打拿极的均值 (比如增大至 6)。运行程序并估计 n_{out} 的标准差与均值的比值。定性解释为什么这么做比所有 ν_i 都相同时的分辨率更好。为什么提高后面的打拿极的增益对提高分辨率作用不大?

- (3) 尝试将程序改成模拟 $N = 12$ 个打拿极。你会发现模拟每个打拿极上每个电子的碰撞需要太长时间。可以考虑换个思路，取 $N = 6$ 运行足够多的事例从而获得足够精确的 n_{out} 的分布 (例如至少 $M \approx 10^4$ ，分 50 个区间作出 $0 \leq n_{\text{out}} \leq 5000$ 之间的直方图)。用某种方法，比如舍选法，产生服从该分布的随机数。对前 6 个打拿极得到的每个电子，用同样方法模拟它在后面 6 个打拿极产生的电子数目。对前 6 个打拿极，取 $\nu_1 = 6$ ，其余 $\nu_i = 3$ ；对后 6 个打拿极，全部取 $\nu_i = 3$ 。

解答：

令 Z_i 表示第 i 个打拿极之后的电子数，初始 $Z_0 = 1$ 。在给定 Z_{i-1} 时，若每个电子在第 i 级产生均值为 ν_i 的泊松个数，则

$$Z_i | Z_{i-1} \sim \text{Pois}(\nu_i Z_{i-1}).$$

于是


$$E[Z_i] = \nu_i E[Z_{i-1}], \quad V[Z_i] = \nu_i E[Z_{i-1}] + \nu_i^2 V[Z_{i-1}].$$

递推得到

$$E[n_{\text{out}}] = \prod_{i=1}^N \nu_i,$$

以及

$$\frac{V[n_{\text{out}}]}{E[n_{\text{out}}]^2} = \sum_{k=1}^N \frac{1}{\prod_{j=1}^k \nu_j}.$$



六级 PMT 的输出电子数模拟；提高第一级平均增益会显著改善相对分辨率。

- (1) 当 $N = 6$ 、所有 $\nu_i = 3$ 时，

$$E[n_{\text{out}}] = 3^6 = 729,$$

$$\sigma_{\text{out}} = 729 \sqrt{\frac{1 - 3^{-6}}{3 - 1}} \simeq 515.$$

若把输出误认为均值 729 的单个泊松变量，则标准差只有 $\sqrt{729} = 27$ 。真实标准差大得多，是因为前几级的涨落会被后续级联倍增并放大。

- (2) 若把第一级提高到 $\nu_1 = 6$ ，其余仍为 3，则均值变为 $6 \cdot 3^5 = 1458$ ，相对分辨率为

$$\frac{\sigma}{E} = \sqrt{\frac{1}{6} + \frac{1}{18} + \frac{1}{54} + \frac{1}{162} + \frac{1}{486} + \frac{1}{1458}} \simeq 0.500.$$

而所有级均为 3 时相对分辨率约为 0.707。提高第一级最有效，因为第一级涨落会被所有后续级放大；提高最后几级主要改变总增益，对已经形成的相对涨落改善很小。

- (3) 直接逐个电子模拟 12 个打拿极会非常慢。更好的做法是利用条件分布

$$Z_i \mid Z_{i-1} \sim \text{Pois}(\nu_i Z_{i-1})$$

逐级抽样一次，而不是对每个电子逐个循环。对 $(\nu_1, \dots, \nu_{12}) = (6, 3, 3, \dots, 3)$ ，理论均值为

$$E[n_{\text{out}}] = 6 \cdot 3^{11} = 1062882,$$

标准差由上面的递推公式给出，约为

$$\sigma_{\text{out}} \simeq 5.31 \times 10^5.$$

这种逐级泊松抽样与逐个电子的完整级联模拟等价，但计算量小得多。

实验物理中的统计方法

第 4 章统计检验

1. 带电粒子穿过气体会发生电离现象，电离的数目与入射粒子的类型有关。假设基于电离的测量构造了某个检验统计量 t ，使其服从高斯分布：如果带电粒子是电子，则高斯分布的均值为 0，标准差为 1；如果带电粒子是 π 介子，则高斯分布的均值为 2，标准差为 1。构造某个检验，通过要求 $t < 1$ 来选择电子事件。
- (1) 该检验的显著水平（significance level）如何？（显著性水平即在拒绝域中接受电子的概率。）
 - (2) 该检验排除粒子为 π 介子的假设的功效（power）多大？有多大概率将 π 介子鉴别为电子？
 - (3) 假定已知样本中包含 99% 的 π 介子和 1% 的电子， $t < 1$ 的判选条件得到的电子样本的纯度（purity）为多少？
 - (4) 假定要求电子样本的纯度至少 95%，应该如何选择统计检验的拒绝域（即判选条件）？如果选用该判选条件，则该检验接受电子的效率为多少，显著性水平多大？




图 4.1: 电子和 π 介子假设下的 t 分布及判选阈值。

解答：

记电子假设下 $t \sim N(0, 1)$ ， π 介子假设下 $t \sim N(2, 1)$ ，电子判选条件为 $t < 1$ 。这里把 $H_0 = \pi$ 看作要被排除的假设，则拒绝域是 $t < 1$ 。

(1) 显著性水平

显著性水平是零假设 $H_0 = \pi$ 为真时落入拒绝域的概率：

$$\alpha = P(t < 1 \mid \pi) = \Phi(1 - 2) = \Phi(-1) = 0.158655.$$

这也是把 π 介子误判为电子的概率。

(2) 功效和误判概率

功效是备择假设（电子）为真时正确拒绝 π 假设的概率：

$$1 - \beta = P(t < 1 \mid e) = \Phi(1) = 0.841345.$$

把 π 介子鉴别为电子的概率仍为

$$P(t < 1 \mid \pi) = 0.158655.$$

(3) 电子样本纯度

若先验比例为 $P(e) = 0.01$ 、 $P(\pi) = 0.99$ ，则

$$\text{purity} = \frac{P(e)P(t < 1 | e)}{P(e)P(t < 1 | e) + P(\pi)P(t < 1 | \pi)}.$$

代入数值得

$$\text{purity} = \frac{0.01 \times 0.841345}{0.01 \times 0.841345 + 0.99 \times 0.158655} = 0.05084,$$

即约 5.1%。虽然电子效率高，但由于 π 背景先验比例太大，判选后纯度仍很低。

(4) 要求纯度至少 95%

把判选条件改为 $t < c$ 。要求

$$\frac{0.01 \Phi(c)}{0.01 \Phi(c) + 0.99 \Phi(c - 2)} \geq 0.95.$$

数值求解等号得到

$$c \simeq -2.5153.$$

于是电子接受效率为

$$\varepsilon_e = P(t < c | e) = \Phi(-2.5153) = 5.95 \times 10^{-3},$$

显著性水平 (π 被误判为电子的概率) 为

$$\alpha = P(t < c | \pi) = \Phi(-4.5153) = 3.16 \times 10^{-6}.$$

若把“以电子为原假设时拒绝电子”的概率称为显著性水平，则它为 $1 - \varepsilon_e = 0.9941$ ；但对本题“排除 π 假设”的检验，通常应使用上面的 $\alpha = 3.16 \times 10^{-6}$ 。

2. 考虑某检验统计量 t 为输入变量 $\mathbf{x} = (x_1, \dots, x_n)$ 的线性组合，系数为 $\mathbf{a} = (a_1, \dots, a_n)$ ，即

$$t(\mathbf{x}) = \sum_{i=1}^n a_i x_i = \mathbf{a}^T \mathbf{x}.$$

假定在 H_0 和 H_1 两个假设下， $\mathbf{x}$ 的均值分别为 μ_0 和 μ_1 ，协方差矩阵分别为 V_0 和 V_1 ，检验统计量 t 的均值分别为 τ_0 和 τ_1 ，方差为 Σ_0^2 和 Σ_1^2 (见 Statistical Data Analysis 第 4.4.1 节)。

(1) 证明：当系数 $\mathbf{a}$ 为 $\mathbf{a} = W^{-1}(\mu_0 - \mu_1)$ 时 (其中 $W = V_0 + V_1$)，下式定义的分变量达到最大值：

$$J(\mathbf{a}) = \frac{(\tau_0 - \tau_1)^2}{\Sigma_0^2 + \Sigma_1^2}.$$

这定义了 Fisher 线性甄别量。

(2) 假定 $V_0 = V_1 = V$ ，且输入变量的概率密度函数 $f(\mathbf{x}|H_0)$ 和 $f(\mathbf{x}|H_1)$ 是多维高斯分布，均值分别为 μ_0 和 μ_1 (参见 Statistical Data Analysis 的式 4.26)。取两个假设的先验概率分别为 π_0 和 π_1 。利用 Bayes 定理，求验后概率 $P(H_0|\mathbf{x})$ 和 $P(H_1|\mathbf{x})$ 作为 t 的函数。

(3) 推广该检验统计量，使其包含一个偏倚：

$$t(\mathbf{x}) = a_0 + \sum_{i=1}^n a_i x_i.$$

证明此时验后概率 $P(H_0|\mathbf{x})$ 可以表示为

$$P(H_0|\mathbf{x}) = \frac{1}{1 + e^{-t}},$$

其中偏倚 a_0 为

$$a_0 = -\frac{1}{2}\mu_0^T V^{-1}\mu_0 + \frac{1}{2}\mu_1^T V^{-1}\mu_1 + \log \frac{\pi_0}{\pi_1}.$$

解答:

定义

$$\Delta\mu = \mu_0 - \mu_1, \quad W = V_0 + V_1.$$

线性统计量 $t(\mathbf{x}) = \mathbf{a}^T \mathbf{x}$ 在两假设下的均值差和方差和为

$$\tau_0 - \tau_1 = \mathbf{a}^T \Delta\mu, \quad \Sigma_0^2 + \Sigma_1^2 = \mathbf{a}^T W \mathbf{a}.$$

因此

$$J(\mathbf{a}) = \frac{(\mathbf{a}^T \Delta\mu)^2}{\mathbf{a}^T W \mathbf{a}}.$$

由 Cauchy-Schwarz 不等式,

$$(\mathbf{a}^T \Delta\mu)^2 = \{\mathbf{a}^T W^{1/2} W^{-1/2} \Delta\mu\}^2 \leq (\mathbf{a}^T W \mathbf{a})(\Delta\mu^T W^{-1} \Delta\mu),$$

等号在 $\mathbf{a} \propto W^{-1} \Delta\mu$ 时成立。比例因子不影响 J , 故可取

$$\mathbf{a} = W^{-1}(\mu_0 - \mu_1).$$

当 $V_0 = V_1 = V$ 且两类都是多维高斯时, 后验概率比为

$$\log \frac{P(H_0 | \mathbf{x})}{P(H_1 | \mathbf{x})} = \log \frac{\pi_0 f(\mathbf{x} | H_0)}{\pi_1 f(\mathbf{x} | H_1)}.$$

展开高斯指数得

$$\log \frac{P(H_0 | \mathbf{x})}{P(H_1 | \mathbf{x})} = a_0 + \mathbf{a}^T \mathbf{x},$$

其中

$$\begin{aligned} \mathbf{a} &= V^{-1}(\mu_0 - \mu_1), \\ a_0 &= -\frac{1}{2}\mu_0^T V^{-1}\mu_0 + \frac{1}{2}\mu_1^T V^{-1}\mu_1 + \log \frac{\pi_0}{\pi_1}. \end{aligned}$$

若最初定义的不含偏置的 Fisher 变量为 $t_F = \mathbf{a}^T \mathbf{x}$, 则

$$P(H_0 | \mathbf{x}) = \frac{1}{1 + \exp[-(a_0 + t_F)]}, \quad P(H_1 | \mathbf{x}) = \frac{1}{1 + \exp[a_0 + t_F]}.$$

若把偏置并入检验统计量

$$t(\mathbf{x}) = a_0 + \sum_i a_i x_i,$$

则

$$P(H_0 | \mathbf{x}) = \frac{1}{1 + e^{-t}}, \quad P(H_1 | \mathbf{x}) = \frac{1}{1 + e^t}.$$

3. 正负电子对撞中观测到具有特殊运动学性质的事件数可以被视为泊松变量。假定对于给定积分亮度 (即给定束流强度时的取数时间), 预期从某已知过程得到的事件数为 3.9, 而实际上观测到 16 个事件。零假设为没有新物理过程对观测到的事件数有贡献; 计算零假设的 P -值。计算泊松分布求和时, 可以利用关系式

$$\sum_{n=0}^m P(n; \nu) = 1 - F_{\chi^2}(2\nu; n_{\text{dof}}),$$

其中 $P(n; \nu)$ 是均值为 ν 的泊松分布的概率, F_{χ^2} 是自由度数目为 $n_{\text{dof}} = 2(m + 1)$ 的 χ^2 分布的累积分布。可以调用 ROOT 里面的 TMath 名字空间下的函数 `TMath::Prob(double chi2, int ndf)` 计算, 或者查表得到。

解答:


零假设下事件数 $n \sim \text{Poisson}(\nu = 3.9)$, 实际观测到 $n = 16$ 。
关心的是“至少这么极端”的上尾概率:

$$P(n \geq 16 \mid \nu = 3.9) = \sum_{n=16}^{\infty} P(n; 3.9).$$

数值为

$$P = 3.58 \times 10^{-6}.$$

这说明在零假设下出现 16 个或更多事件的概率极小, 零假设被强烈拒绝。



$\nu = 3.9$ 的泊松分布; 阴影部分对应观测到 $n \geq 16$ 的上尾。

4. 表 4.1 是实验获取的分区间数据和理论预言值。第二、三列是区间边界, 第四列是对应区间的观测事件数 n_i ($i = 1, \dots, 20$), 服从泊松分布。第五、六列是两种理论对期待值 $\nu_i = E[n_i]$ 的预言, 如图 4.2 所示。

- (1) 写一段程序, 将表中 20 个区间的实验观测值和理论预期值画成直方图, 画到一张图上, 并根据 Statistical Data Analysis 的式 (4.39) 计算 χ^2 统计量。
- (2) 因为很多区间的事件数很小甚至为零, 前面计算的统计量不太可能服从 χ^2 分布。写一段程序, 根据两种理论假设 (theory1 和 theory2) 给出真实的 χ^2 分布。如果利用 (a) 中的数据计算统计检验, 其 P -值是多少? 如果利用正常的 χ^2 分布计算, P -值是多少?

序号	$x_{\min}$	$x_{\max}$	n (data)	ν (theory1)	ν (theory2)
1	0.0	0.5	1	0.2	0.2
2	0.5	1.0	0	1.2	0.7
3	1.0	1.5	3	1.9	1.1
4	1.5	2.0	4	3.2	1.6
5	2.0	2.5	6	4.0	1.9
6	2.5	3.0	3	4.5	2.2
7	3.0	3.5	3	4.7	2.7

序号	$x_{\min}$	$x_{\max}$	n (data)	ν (theory1)	ν (theory2)
8	3.5	4.0	4	4.8	3.3
9	4.0	4.5	5	4.8	3.6
10	4.5	5.0	7	4.5	3.9
11	5.0	5.5	4	4.1	4.0
12	5.5	6.0	5	3.5	4.0
13	6.0	6.5	2	3.0	3.9
14	6.5	7.0	0	2.4	3.5
15	7.0	7.5	1	1.6	3.2
16	7.5	8.0	0	0.9	2.8
17	8.0	8.5	0	0.5	2.2
18	8.5	9.0	1	0.3	1.5
19	9.0	9.5	0	0.2	1.0
20	9.5	10.0	0	0.1	0.5

表 4.1: 实验获取的分区间数据和理论预言值。第二、三列是区间边界。




图 4.2: 表 4.1 的观测数据及两种理论预言。

解答:

表 4.1 中的观测值为 n_i ，两种理论给出期望 ν_i 。按题目所指的 Pearson 型统计量（书中式 4.39）应取

$$\chi^2 = \sum_i \frac{(n_i - \nu_i)^2}{\nu_i}.$$

代入 20 个区间的数据得到

$$\chi_{\text{theory1}}^2 = 15.8193, \quad \chi_{\text{theory2}}^2 = 35.9653.$$

若直接近似为自由度 20 的 χ^2 分布，则

$$P_{\chi^2}(\text{theory1}) = 0.7278, \quad P_{\chi^2}(\text{theory2}) = 0.0155.$$


由于许多区间的期望事件数很小，Pearson 统计量的真实分布不一定很好地服从 χ_{20}^2 。更可靠的做法是：在某个理论 ν_i 下为每个 bin 产生独立泊松伪数据 n_i^{MC} ，每组都计算同一个 χ_{MC}^2 ，再用

$$P_{\text{MC}} = P(\chi_{\text{MC}}^2 \geq \chi_{\text{obs}}^2)$$

估计真实 P -值。用大量伪实验可得到近似结果

$$P_{\text{MC}}(\text{theory1}) \simeq 0.65, \quad P_{\text{MC}}(\text{theory2}) \simeq 0.036.$$

结论是：theory1 与数据相容；theory2 的 P -值较小，拟合明显较差。



各区间对 Pearson χ^2 的贡献；theory2 在高 x 区间贡献明显偏大。

若改用泊松似然比 deviance

$$2 \sum_i \left[\nu_i - n_i + n_i \log \frac{n_i}{\nu_i} \right]$$

也可以做检验，但那不是本题式 (4.39) 所要求的 Pearson 统计量。

5. 在放射性实验中，卢瑟福和盖革记录了固定时间间隔内 α 衰变的次数。数据如表 4.2 所示。假定放射源中放射性核素的数目非常大，且任意一个核素在小时间间隔内发射一个 α 粒子的概率很小，则可以认为在时间间隔 Δt 内发生衰变的次数 m 服从泊松分布。如果观测结果与泊松分布的假设存在差异，则表明核素的 α 衰变不相互独立，比如某个核素发生 α 衰变可能会引发邻近核素也发生衰变，从而在短时间间隔内形成衰变簇团。

(1) 利用表 4.2 的数据，计算样本均值

$$\bar{m} = \frac{1}{n_{\text{tot}}} \sum_m n_m m,$$

以及样本方差

$$s^2 = \frac{1}{n_{\text{tot}} - 1} \sum_m n_m (m - \bar{m})^2.$$

m	n_m	m	n_m
0	57	8	45
1	203	9	27
2	383	10	10
3	525	11	4
4	532	12	0
5	408	13	1

m	n_m	m	n_m
6	273	14	1
7	139	>14	0

表 4.2: 卢瑟福与盖革实验数据, 即在时间间隔 $\Delta t = 7.5 \text{ s}$ 内发生 m 次 α 衰变的次数。

其中 n_m 是发生 m 个衰变的次数, $n_{\text{tot}} = \sum_m n_m = 2608$ 是测量时间内总衰变次数。求和从 $m = 0$ 一直到测量时间内最大的衰变次数 (次数为 $m = 14$)。利用 $\bar{m}$ 和 s^2 , 求分散度

$$t = \frac{s^2}{\bar{m}}.$$

$\bar{m}$ 和 s^2 分别为 m 的均值和方差的估计量 (参见 Statistical Data Analysis 第 5 章); 如果 m 服从泊松分布, 则 $\bar{m}$ 和 s^2 应该相等, 于是可以预期 t 大约为 1。可以证明对于泊松分布, 当 n_{tot} 很大时, $(n_{\text{tot}} - 1)t$ 服从自由度为 $n_{\text{tot}} - 1$ 的 χ^2 分布。而且, 当 n_{tot} 很大时, 该分布变成均值为 $n_{\text{tot}} - 1$, 方差为 $2(n_{\text{tot}} - 1)$ 的高斯分布。

- (2) m 服从泊松分布这一假设的 P -值为多少? 为了表征 t 的观测值与泊松假设相符或不相符, 应该选取什么样的 t 值 (即 t 大表示相符还是 t 小表示相符)?
- (3) 写一段蒙特卡罗程序产生很多组数据, 每组数据包含 n_{tot} 个服从泊松分布的 m 值。(泊松分布的随机数可以在 ROOT 中直接调用, `gRandom->Poisson( $\nu$ )`。)对于 m 的均值, 可以取表 4.2 中数据的均值 $\bar{m}$ 。对于每组数据, 计算 t 的值并填充至直方图。利用直方图和从卢瑟福实验数据得到的 t 值, 计算泊松假设的 P -值。将该结果与 (a) 中的结果进行比较。(选作: 将 $(n_{\text{tot}} - 1)t$ 记录至直方图, 与均值为 $n_{\text{tot}} - 1$, 方差为 $2(n_{\text{tot}} - 1)$ 的高斯分布进行比较。)

解答:

表 4.2 给出在固定时间窗 $\Delta t = 7.5 \text{ s}$ 内, 发生 m 次 α 衰变的次数 n_m 。

- (1) 样本均值与样本方差
总样本数

$$n_{\text{tot}} = \sum_m n_m = 2608.$$

样本均值

$$\bar{m} = \frac{1}{n_{\text{tot}}} \sum_m n_m m = 3.871549.$$

样本方差

$$s^2 = \frac{1}{n_{\text{tot}} - 1} \sum_m n_m (m - \bar{m})^2 = 3.696191.$$

分散度统计量

$$t = \frac{s^2}{\bar{m}} = 0.954706.$$

若严格服从泊松分布, 应有 $t \approx 1$ 。

- (2) P 值应看哪一侧?

若问题是“是否与泊松分布一致”, 则偏大和偏小都表示不一致, 因此应该使用双侧 P 值。

又因为本题实际观测到 $t < 1$, 所以若只看单侧, 应看下尾。

利用大样本近似

$$(n_{\text{tot}} - 1)t \sim \chi^2_{n_{\text{tot}} - 1},$$

得到

- 下尾: $P_{\text{lower}} = 0.04933$
- 上尾: $P_{\text{upper}} = 0.95067$
- 双侧:

$$P_{2s} = 2 \min(P_{\text{lower}}, P_{\text{upper}}) = 0.09866.$$


(3) 蒙特卡罗检验

程序用 $\lambda = \bar{m}$ 生成很多组 Poisson 数据，每组都含 $n_{\text{tot}} = 2608$ 个观测，再计算 t 。得到

- $P_{\text{lower,MC}} = 0.05013$
- $P_{\text{upper,MC}} = 0.94988$
- $P_{\text{two sided,MC}} = 0.10025$

与 χ^2 近似非常一致。

结论：本数据的 $t = 0.9547$ 比 1 略小，但双侧 P 值约为 0.10，不足以强烈拒绝泊松假设，因此这组数据与泊松统计基本相容。



卢瑟福-盖革数据与均值取样本均值的泊松模型比较。

实验物理中的统计方法

第 5 章参数估计的一般概念

1. 考虑随机数 x ，其均值和方差分别为 μ 和 σ^2 。假设样本空间由 n 次观测结果 $x_1, x_2, \dots, x_n$ 构成。本题的目的是证明样本均值

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

为均值 μ 的一致性估计量。

- (1) 第一步要证明 Chebyshev 不等式，即只要 x 的方差存在，对任意 $a > 0$ ，下面式子成立：

$$P(|x - \mu| \geq a) \leq \frac{\sigma^2}{a^2}.$$

该式的证明需要用到方差的定义，

$$\sigma^2 = \int_{-\infty}^{\infty} (x - \mu)^2 f(x) dx,$$

其中 $f(x)$ 为随机变量 x 的概率密度函数。利用如下事实：如果积分区域限定为 $|x - \mu| \geq a$ ，则积分 (5.3) 会变小，如果用 a^2 替换 $(x - \mu)^2$ ，则积分会更小。

- (2) 利用 Chebyshev 不等式证明大数弱定理，即，对任意 $\epsilon > 0$ ，

$$\lim_{n \rightarrow \infty} P\left(\left|\frac{1}{n} \sum_{i=1}^n x_i - \mu\right| \geq \epsilon\right) = 0.$$

这等价于， $\bar{x}$ 是 μ 的一致性估计量，只要 x 的方差存在。

解答：

设随机变量 x 的均值与方差分别为 μ, σ^2 ，样本均值为

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i.$$

- (1) 证明 Chebyshev 不等式
由方差定义

$$\sigma^2 = E[(x - \mu)^2] = \int_{-\infty}^{\infty} (x - \mu)^2 f(x) dx.$$

在区域 $|x - \mu| \geq a$ 上，恒有 $(x - \mu)^2 \geq a^2$ ，于是

$$\sigma^2 \geq \int_{|x-\mu| \geq a} (x - \mu)^2 f(x) dx \geq a^2 \int_{|x-\mu| \geq a} f(x) dx.$$

因此

$$P(|x - \mu| \geq a) \leq \frac{\sigma^2}{a^2}.$$

这就是 Chebyshev 不等式。

- (2) 用 Chebyshev 证明大数弱定理

若 $x_1, \dots, x_n$ 独立同分布，均值为 μ ，方差为 σ^2 ，则

$$E[\bar{x}] = \mu, \quad V[\bar{x}] = \frac{\sigma^2}{n}.$$

对任意 $\varepsilon > 0$, 由 Chebyshev 不等式,

$$P(|\bar{x} - \mu| \geq \varepsilon) \leq \frac{V[\bar{x}]}{\varepsilon^2} = \frac{\sigma^2}{n\varepsilon^2} \xrightarrow{n \rightarrow \infty} 0.$$

故 $\bar{x}$ 依概率收敛到 μ , 即 $\bar{x}$ 是 μ 的一致估计量。

2. 考虑均值为 μ , 方差为 σ^2 的随机变量 x , 并得到样本值为 $x_1, x_2, \dots, x_n$ 的样本空间。

(1) 假设均值 μ 已经利用样本均值 $\bar{x}$ 估计。证明样本方差

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2 = \frac{n}{n-1} (\overline{x^2} - \bar{x}^2)$$

为方差 σ^2 的无偏估计量。(利用 $E[x_i x_j] = \mu^2$ ($i \neq j$), $E[x_i^2] = \mu^2 + \sigma^2$ ($i = 1, 2, \dots, n$)。)

(2) 假设均值 μ 已知。证明 σ^2 的无偏估计量为

$$S^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \mu)^2 = \overline{x^2} - \mu^2.$$

解答:

样本方差定义为

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2.$$

先用恒等式

$$\sum_{i=1}^n (x_i - \bar{x})^2 = \sum_{i=1}^n (x_i - \mu)^2 - n(\bar{x} - \mu)^2.$$

两边取期望:

$$E \left[\sum_{i=1}^n (x_i - \bar{x})^2 \right] = n\sigma^2 - nV(\bar{x}) = n\sigma^2 - n\frac{\sigma^2}{n} = (n-1)\sigma^2.$$

因此

$$E[s^2] = \sigma^2.$$

所以 s^2 是无偏估计量。

(2) 若均值 μ 已知, 证明

$$S^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \mu)^2$$

是 σ^2 的无偏估计。

直接取期望:

$$E[S^2] = \frac{1}{n} \sum_{i=1}^n E[(x_i - \mu)^2] = \frac{1}{n} \sum_{i=1}^n \sigma^2 = \sigma^2.$$

因此 S^2 无偏。

3.

(1) 证明样本方差 s^2 (5.5) 的方差为

$$V[s^2] = E[s^4] - (E[s^2])^2 = \frac{1}{n} \left(\mu_4 - \frac{n-3}{n-1} \mu_2^2 \right),$$

其中 $\mu_k = E[(x - \mu)^k]$ 为 x 的 k 阶中心矩。为此, 需要先证明 s^2 可以写为

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n x_i^2 - \frac{1}{n(n-1)} \sum_{i,j=1}^n x_i x_j.$$

然后证明 s^4 的期待值为

$$\begin{aligned} E[s^4] &= \frac{1}{(n-1)^2} \sum_{i,j=1}^n E[x_i^2 x_j^2] - \frac{2}{n(n-1)^2} \sum_{i,j,k=1}^n E[x_i x_j x_k^2] \\ &\quad + \frac{1}{n^2(n-1)^2} \sum_{i,j,k,l=1}^n E[x_i x_j x_k x_l]. \end{aligned}$$

计算每个求和给出多少项代数矩 μ'_4 或 μ_2^2 。注意其余所有项都含 μ 的一次项或高次项。令 $\mu = 0$, 将结果表示为中心矩 μ_2 和 μ_4 的函数。从中减掉本章第 2 题得到的 $(E[s^2])^2$ 即可得到结果。

(2) 如果 x 服从高斯分布, 计算 s^2 的方差。利用高斯分布的 4 阶中心矩为 $\mu_4 = 3\sigma^4$ 。

解答:

$$V[s^2] = E[s^4] - (E[s^2])^2 = \frac{1}{n} \left(\mu_4 - \frac{n-3}{n-1} \mu_2^2 \right),$$

其中 $\mu_k = E[(x - \mu)^k]$ 是中心矩。

把随机变量平移到均值为 0 的情形 (不影响方差与中心矩), 写成

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n x_i^2 - \frac{1}{n(n-1)} \sum_{i,j=1}^n x_i x_j.$$

接着平方并对所有指标重合方式分类求期望:

- 四个指标全不相同;
- 有两个指标重合;
- 三个重合;
- 两对重合;
- 四个全重合。

由于独立同分布且 $E[x] = 0$, 许多项会消失, 只剩下由 $\mu_2 = E[x^2]$ 与 $\mu_4 = E[x^4]$ 组成的项。整理后可得

$$E[s^4] = \frac{1}{n} \mu_4 + \frac{n^2 - 2n + 3}{n(n-1)} \mu_2^2,$$

再减去

$$(E[s^2])^2 = \mu_2^2,$$

便得到题目给出的结果:

$$V[s^2] = \frac{1}{n} \left(\mu_4 - \frac{n-3}{n-1} \mu_2^2 \right).$$

(2) 若 x 服从高斯分布
高斯分布满足

$$\mu_2 = \sigma^2, \quad \mu_4 = 3\sigma^4.$$

代回上式:

$$V[s^2] = \frac{1}{n} \left(3\sigma^4 - \frac{n-3}{n-1} \sigma^4 \right) = \frac{2\sigma^4}{n-1}.$$

实验物理中的统计方法

第 6 章最大似然法

1.

- (1) 给定一组服从高斯分布的数据样本 $x_1, \dots, x_n$, 求均值 μ 和方差 σ^2 的最大似然估计量。
- (2) 将估计量 $\hat{\mu}$ 和 $\hat{\sigma}^2$ 同《统计数据分析》第 5 章定义的估计量 $\bar{x}$ 和 s^2 联系起来, 计算 $\hat{\mu}$ 和 $\hat{\sigma}^2$ 的期待值和方差。
- (3) 通过计算

$$(V^{-1})_{ij} = -E \left[\frac{\partial^2 \log L}{\partial \theta_i \partial \theta_j} \right],$$

近似求解协方差矩阵的逆 (大统计样本有效)。其中 θ_i 和 θ_j ($i, j = 1, 2$) 分别为 μ 和 σ^2 。对 V^{-1} 求逆, 计算出协方差矩阵, 并将对角元素 (方差) 与 (b) 中求得的精确值比较。注意到, 在大样本极限下, (b) 和 (c) 的结果符合。

解答:

设 $x_1, \dots, x_n$ 独立同分布于 $N(\mu, \sigma^2)$ 。

- (1) 求 $\hat{\mu}, \hat{\sigma}^2$
对数似然为

$$\log L(\mu, \sigma^2) = -\frac{n}{2} \log(2\pi) - \frac{n}{2} \log \sigma^2 - \frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2.$$

对 μ 求偏导:

$$\frac{\partial \log L}{\partial \mu} = \frac{1}{\sigma^2} \sum_{i=1}^n (x_i - \mu) = 0 \quad \Rightarrow \quad \hat{\mu} = \bar{x}.$$

再对 σ^2 求偏导:

$$\frac{\partial \log L}{\partial \sigma^2} = -\frac{n}{2\sigma^2} + \frac{1}{2\sigma^4} \sum_{i=1}^n (x_i - \hat{\mu})^2 = 0,$$

所以

$$\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2.$$

- (2) 期望与方差
由样本均值的性质:

$$E[\hat{\mu}] = \mu, \quad V[\hat{\mu}] = \frac{\sigma^2}{n}.$$

又因为

$$\hat{\sigma}^2 = \frac{n-1}{n} s^2,$$

而第五章已知 $E[s^2] = \sigma^2$, 高斯情形下

$$V[s^2] = \frac{2\sigma^4}{n-1},$$

所以

$$E[\hat{\sigma}^2] = \frac{n-1}{n}\sigma^2, \quad V[\hat{\sigma}^2] = \left(\frac{n-1}{n}\right)^2 \frac{2\sigma^4}{n-1} = \frac{2(n-1)}{n^2}\sigma^4.$$

(3) Fisher 信息近似协方差矩阵

取参数 $\theta = (\mu, \sigma^2)$, 可算得 Fisher 信息矩阵

$$I(\theta) = \begin{pmatrix} \frac{n}{\sigma^2} & 0 \\ 0 & \frac{n}{2\sigma^4} \end{pmatrix}.$$

故大样本下

$$\text{Cov}(\hat{\theta}) \approx I^{-1}(\theta) = \begin{pmatrix} \frac{\sigma^2}{n} & 0 \\ 0 & \frac{2\sigma^4}{n} \end{pmatrix}.$$

其中右下角是大样本极限: 精确结果是 $2(n-1)\sigma^4/n^2$ 。

2. 考虑某二项分布变量, 即 N 次试验中成功的次数 n , 单个实验试验成功的概率为 p 。如果只进行一次观测得到 n , p 的最大似然估计量为多少? 证明 $\hat{p}$ 是无偏的, 并求其方差。证明 $\hat{p}$ 的方差等于最小方差边界 (见《统计数据分析》(6.16) 式)。

解答:

若单次观测到成功次数 n , 总试验数为 N , 则

$$P(n | N, p) = \binom{N}{n} p^n (1-p)^{N-n}.$$

对数似然:

$$\log L = n \log p + (N-n) \log(1-p) + C.$$

求导并令其为零:

$$\frac{n}{p} - \frac{N-n}{1-p} = 0 \Rightarrow \hat{p} = \frac{n}{N}.$$

无偏性:

$$E[\hat{p}] = \frac{E[n]}{N} = p.$$

方差:

$$V[\hat{p}] = \frac{V[n]}{N^2} = \frac{Np(1-p)}{N^2} = \frac{p(1-p)}{N}.$$

二项分布的 Fisher 信息为 $I(p) = N/[p(1-p)]$, 故 CRLB 为 $p(1-p)/N$, 刚好达到下界, 因此 $\hat{p}$ 是有效估计量。

3.

- (1) 重新考虑二项分布的随机变量 n , 每次试验结果 (成功或失败) 的概率为 p 和 $q = 1-p$ 。利用本章第 2 题得到的 p 的估计量, 构造不对称度

$$\alpha = p - q = 2p - 1$$

的最大似然估计量 $\hat{\alpha}$, 并求标准差 $\sigma_{\hat{\alpha}}$ 。

- (2) 假设需要测量某个非常小的不对称度, 预计大约是 $\alpha \approx 10^{-3}$ 水平。如果要求标准差不大于 α 的三分之一, 至少需要多少次试验?

解答:

- (1) MLE 与标准差
由不变性,

$$\hat{\alpha} = 2\hat{p} - 1 = 2\frac{n}{N} - 1.$$

因为 $\alpha = 2p - 1$, 故 $p = (1 + \alpha)/2$, 于是

$$V[\hat{\alpha}] = 4V[\hat{p}] = \frac{4p(1-p)}{N} = \frac{1 - \alpha^2}{N}.$$

所以

$$\sigma_{\hat{\alpha}} = \sqrt{\frac{1 - \alpha^2}{N}}.$$

- (2) 估计所需试验次数
若 $\alpha \approx 10^{-3}$, 要求

$$\sigma_{\hat{\alpha}} \leq \frac{\alpha}{3},$$

则近似 $1 - \alpha^2 \approx 1$, 得到

$$\frac{1}{\sqrt{N}} \lesssim \frac{10^{-3}}{3} \Rightarrow N \gtrsim 9 \times 10^6.$$

4. 考虑泊松变量的单次观测值 n 。均值 ν 的最大似然估计量为多少? 证明该估计量是无偏的并求其方差。证明 $\hat{\nu}$ 的方差等于最小方差边界。

解答:

若单次观测 $n_0 \sim \text{Poisson}(\nu)$, 则

$$P(n_0 | \nu) = e^{-\nu} \frac{\nu^{n_0}}{n_0!}.$$

对数似然

$$\log L = -\nu + n_0 \log \nu + C.$$

求导:

$$-1 + \frac{n_0}{\nu} = 0 \Rightarrow \hat{\nu} = n_0.$$

于是

$$E[\hat{\nu}] = E[n_0] = \nu, \quad V[\hat{\nu}] = V[n_0] = \nu.$$

泊松分布的 Fisher 信息为 $I(\nu) = 1/\nu$, 故 CRLB 为 ν , 等于估计量方差, 因此它也是有效估计量。

5. 支持粒子物理标准模型的早期证据是观测到左手 (R) 和右手 (L) 极化的电子与氘靶的非弹散射截面 σ_R 和 σ_L 不同。对于给定积分亮度 L (正比于电子束流密度以及取数时间), 两种类型的事例数 n_R 和 n_L 均为泊松变量, 平均值分别为 ν_R 和 ν_L 。均值与散射截面的关系为 $\nu_R = \sigma_R L$ 和 $\nu_L = \sigma_L L$, 并且实验中两种情形的亮度 L 相同。利用习题的结果, 构造计划不对称度的估计量 $\hat{\alpha}$,

$$\alpha = \frac{\sigma_R - \sigma_L}{\sigma_R + \sigma_L},$$

利用误差传递, 求标准差 $\sigma_{\hat{\alpha}}$, 用 α 和 $\nu_{\text{tot}} = \nu_R + \nu_L$ 表示。将此与本章第 3 题的结果进行比较。预计不对称度大约为 10^{-4} 水平, 要想使 $\sigma_{\hat{\alpha}}$ 比不对称度小一个数量级, 需要多少散射事例? (事例数非常大, 以至于事例不能单独记录下来, 而是测量探测器输出电流。参见 C.Y. Prescott et al., Parity non-conservation in inelastic electron scattering, Phys. Lett. B77(1978)347.)

解答:

由

$$\alpha = \frac{\sigma_R - \sigma_L}{\sigma_R + \sigma_L} = \frac{\nu_R - \nu_L}{\nu_R + \nu_L}$$

可取自然估计量

$$\hat{\alpha} = \frac{n_R - n_L}{n_R + n_L}.$$

记 $N = n_R + n_L$ 。对函数 $g(n_R, n_L) = (n_R - n_L)/(n_R + n_L)$, 有

$$\frac{\partial g}{\partial n_R} = \frac{2n_L}{N^2}, \quad \frac{\partial g}{\partial n_L} = -\frac{2n_R}{N^2}.$$

用误差传播并代入 $V[n_R] = \nu_R$ 、 $V[n_L] = \nu_L$ 得

$$V[\hat{\alpha}] \approx \left(\frac{2\nu_L}{\nu_{\text{tot}}^2}\right)^2 \nu_R + \left(\frac{2\nu_R}{\nu_{\text{tot}}^2}\right)^2 \nu_L = \frac{4\nu_R \nu_L}{\nu_{\text{tot}}^3}.$$

又

$$\nu_R = \frac{1 + \alpha}{2} \nu_{\text{tot}}, \quad \nu_L = \frac{1 - \alpha}{2} \nu_{\text{tot}},$$

所以

$$V[\hat{\alpha}] \approx \frac{1 - \alpha^2}{\nu_{\text{tot}}}, \quad \sigma_{\hat{\alpha}} = \sqrt{\frac{1 - \alpha^2}{\nu_{\text{tot}}}}.$$

这与第 6 章第 3 题的二项模型结果形式相同: 固定总数时 N 被这里的期望总事例数 ν_{tot} 取代。若 $\alpha \sim 10^{-4}$, 并要求标准差比不对称度小一个数量级, 即 $\sigma_{\hat{\alpha}} \leq 10^{-5}$, 则在 $\alpha^2 \ll 1$ 下需要

$$\nu_{\text{tot}} \gtrsim \frac{1}{(10^{-5})^2} = 10^{10}.$$

也就是说需要约 10^{10} 个散射事例量级。

6. 随机变量 x 服从分布 $f(x; \theta)$, 其中 θ 为未知参数。考虑样本空间 $\mathbf{x} = (x_1, \dots, x_n)$, 以此构造 θ 的估计量 $\hat{\theta}(\mathbf{x})$ (不限于最大似然估计量)。证明 Rao-Cramér-Fréchet (RCF) 不等式

$$V[\hat{\theta}] \geq \frac{\left(1 + \frac{\partial b}{\partial \theta}\right)^2}{-E\left[\frac{\partial^2 \log L}{\partial \theta^2}\right]},$$

其中 $b = E[\hat{\theta}] - \theta$ 为估计量的偏置。可分以下几步证明:

- (1) 首先, 证明 Cauchy-Schwarz 不等式, 即对任意两个随机变量 u 和 v ,

$$V[u]V[v] \geq (\text{cov}[u, v])^2,$$

其中 $V[u]$ 和 $V[v]$ 为方差, $\text{cov}[u, v]$ 为协方差。利用 $\alpha u + v$ 的方差必定大于等于零 (对任意 α)。然后考虑特殊情形 $\alpha = (V[v]/V[u])^{1/2}$ 。

- (2) 利用 Cauchy-Schwarz 不等式, 令

$$u = \hat{\theta}, \quad v = \frac{\partial}{\partial \theta} \log L,$$

其中 $L = f_{\text{joint}}(\mathbf{x}; \theta)$ 为似然函数，也是 $\mathbf{x}$ 的联合概率密度函数。代入 (6.5)，表示出 $V[\hat{\theta}]$ 的下界。这里要注意的是，我们将似然函数看成 $\mathbf{x}$ 的函数，即似然函数本身也是一个随机变量。

(3) 假设对 θ 的微分可以移到积分的外面，证明

$$E \left[\frac{\partial}{\partial \theta} \log L \right] = \frac{\partial}{\partial \theta} \int \cdots \int f_{\text{joint}}(\mathbf{x}; \theta) dx_1 \cdots dx_n = 0.$$

我们将推导的 RCF 不等式的形式依赖于该假设，这在感兴趣的问题中一般都成立。（只要积分的极限不依赖于 θ ，该假设总是成立的。）利用 (6.7) 与 (6.5)、(6.6)，证明

$$V[\hat{\theta}] \geq \frac{\left(E \left[\hat{\theta} \frac{\partial \log L}{\partial \theta} \right] \right)^2}{E \left[\left(\frac{\partial \log L}{\partial \theta} \right)^2 \right]}.$$

(4) 证明 (6.8) 的分子可以表示为

$$E \left[\hat{\theta} \frac{\partial \log L}{\partial \theta} \right] = 1 + \frac{\partial b}{\partial \theta},$$

分母可以表示为

$$E \left[\left(\frac{\partial \log L}{\partial \theta} \right)^2 \right] = -E \left[\frac{\partial^2 \log L}{\partial \theta^2} \right].$$

再次假设对 θ 的微分与对 x 的积分可以互换次序。将 (c) 和 (d) 的结果放到一起即可证明 (6.4)。

解答：

记 score 为

$$U(\theta) = \frac{\partial}{\partial \theta} \log L.$$

题目中的正则条件保证对 θ 的微分可与积分交换。

(1) 对任意随机变量 u, v ，由 $V[\alpha u + v] \geq 0$ 对所有 α 成立，二次式判别式非正，得

$$V[u]V[v] \geq \text{cov}(u, v)^2.$$

这就是 Cauchy-Schwarz 不等式的方差形式。

(2) 取 $u = \hat{\theta}$ 、 $v = U(\theta)$ ，则

$$V[\hat{\theta}] \geq \frac{\text{cov}(\hat{\theta}, U)^2}{V[U]}.$$

(3) 因为 L 作为联合密度满足 $\int L(\mathbf{x}; \theta) d\mathbf{x} = 1$ ，所以

$$E[U] = \int L \frac{\partial \log L}{\partial \theta} d\mathbf{x} = \int \frac{\partial L}{\partial \theta} d\mathbf{x} = \frac{\partial}{\partial \theta} 1 = 0.$$

因此 $\text{cov}(\hat{\theta}, U) = E[\hat{\theta}U]$ ，且 $V[U] = E[U^2]$ 。

(4) 设偏置 $b(\theta) = E[\hat{\theta}] - \theta$ 。由于估计量函数本身不显含 θ ，

$$\frac{\partial}{\partial \theta} E[\hat{\theta}] = \frac{\partial}{\partial \theta} \int \hat{\theta} L d\mathbf{x} = \int \hat{\theta} \frac{\partial L}{\partial \theta} d\mathbf{x} = E[\hat{\theta}U].$$

另一方面 $E[\hat{\theta}] = \theta + b(\theta)$ ，所以

$$E[\hat{\theta}U] = 1 + \frac{\partial b}{\partial \theta}.$$

又由 $E[U] = 0$ 再对 θ 求导:

$$0 = \frac{\partial}{\partial \theta} E[U] = E \left[\frac{\partial U}{\partial \theta} \right] + E[U^2] = E \left[\frac{\partial^2 \log L}{\partial \theta^2} \right] + E[U^2].$$

故

$$E[U^2] = -E \left[\frac{\partial^2 \log L}{\partial \theta^2} \right].$$

代回 Cauchy-Schwarz 不等式得到

$$V[\hat{\theta}] \geq \frac{(1 + \partial b / \partial \theta)^2}{-E[\partial^2 \log L / \partial \theta^2]}.$$

无偏情形 $b = 0$ 时恢复标准 Cramér-Rao 下界。

7. 写一段程序, 根据指数分布

$$f(t; \tau) = \frac{1}{\tau} e^{-t/\tau}, \quad t \geq 0,$$

产生样本容量为 n 的样本 $(t_1, \dots, t_n)$ 。

- (1) 证明 τ 的最大似然估计量由样本平均 $\hat{\tau} = \frac{1}{n} \sum_{i=1}^n t_i$ 给出。产生 1000 个 $\tau = 1$, $n = 10$ 的样本。对每个样本计算 $\hat{\tau}$ 并做直方图。比较 $\hat{\tau}$ 的均值与真值 $\tau = 1$ 。
- (2) 假设 t 的概率密度函数的参数为 $\lambda = 1/\tau$, 即

$$f(t; \lambda) = \lambda e^{-\lambda t}, \quad t \geq 0,$$

证明 λ 的最大似然估计量为 $\hat{\lambda} = 1/\sum_{i=1}^n t_i$ 。修改 (a) 中的程序, 加入 $\hat{\lambda}$ 的直方图。比较 $\hat{\lambda}$ 的均值与真值 $\lambda = 1$ 。对 $n = 5, 10, 100$ 三种情况, 分别数值计算偏置 $b = E[\hat{\lambda}] - \lambda$ 。

解答:

指数分布均值参数形式为

$$f(t; \tau) = \frac{1}{\tau} e^{-t/\tau}, \quad t \geq 0.$$

样本对数似然为

$$\log L = -n \log \tau - \frac{1}{\tau} \sum_{i=1}^n t_i.$$

令导数为零:

$$-\frac{n}{\tau} + \frac{1}{\tau^2} \sum_i t_i = 0,$$

得到

$$\hat{\tau} = \frac{1}{n} \sum_{i=1}^n t_i = \bar{t}.$$

并且

$$E[\hat{\tau}] = \tau, \quad V[\hat{\tau}] = \frac{\tau^2}{n}.$$

因此 $\hat{\tau}$ 无偏; 对 $\tau = 1, n = 10$ 的 1000 次模拟, $\hat{\tau}$ 的直方图应以 1 为中心, 标准差约为 $1/\sqrt{10}$ 。若改用率参数 $\lambda = 1/\tau$, 密度为

$$f(t; \lambda) = \lambda e^{-\lambda t}.$$

对数似然为

$$\log L = n \log \lambda - \lambda \sum_i t_i.$$

令导数为零得

$$\hat{\lambda} = \frac{n}{\sum_i t_i} = \frac{1}{\bar{t}}.$$

因此率参数的最大似然估计量为样本均值的倒数；若使用 $1/\sum_i t_i$ ，则它不是 n 个独立样本下的最大似然估计量。

因为 $S = \sum_i t_i \sim \text{Gamma}(n, \text{rate} = \lambda)$ ，当 $n > 1$ 时

$$E\left[\frac{1}{S}\right] = \frac{\lambda}{n-1},$$


所以

$$E[\hat{\lambda}] = n E\left[\frac{1}{S}\right] = \lambda \frac{n}{n-1}, \quad b = E[\hat{\lambda}] - \lambda = \frac{\lambda}{n-1}.$$

对 $\lambda = 1$ ，三个样本量的偏置为

$$b(n=5) = 0.25, \quad b(n=10) = 0.1111, \quad b(n=100) = 0.01010.$$

因此 $\hat{\lambda}$ 有正偏，但偏置随 n 增大而消失。



$\hat{\lambda} = 1/\bar{t}$ 的模拟分布：小样本时右偏明显，且均值高于真值。

8. 日内瓦的出租车牌照号是从 1 一直到总数目 N_{taxi} 。对牌照的 N 次观测得到观测数字 $n_1, \dots, n_N$ 。

- (1) 构造出租车总数目的最大似然估计量。这是最大似然估计量有偏并且无效的常见例子；困难的根源在于数据的边界依赖于参数。
- (2) 提出出租车数目更好的估计量并给出均值和方差。

解答：

设真实牌照从 1 到 N_{taxi} ，观测到 N 次号码 $n_1, \dots, n_N$ ，记最大值为

$$m = \max(n_1, \dots, n_N).$$

(1) 最大似然估计

当 $N_{\text{taxi}} \geq m$ 时，似然与 N_{taxi} 成反比：

$$L(N_{\text{taxi}}) \propto N_{\text{taxi}}^{-N}.$$

它随 N_{taxi} 单调下降, 所以最大似然估计是边界点

$$\hat{N}_{\text{ML}} = m.$$

它显然偏小。

- (2) 更好的估计
经典无偏估计是

$$\hat{N} = \frac{N+1}{N}m - 1.$$

方差为

$$V[\hat{N}] = \frac{(N_{\text{taxi}} - N)(N_{\text{taxi}} + 1)}{N(N+2)}.$$

9. 考虑 N 个独立的泊松变量 $n_1, \dots, n_N$, 均值为 $\nu_1, \dots, \nu_N$ 。假设均值依赖于某可控变量 x ,

$$\nu(x) = \theta a(x),$$

其中 θ 为未知参数, $a(x)$ 为任意已知函数。 N 个 ν_i 因而可以由 $\nu(x_i) = \theta a(x_i)$ 给出, 其中假设 $x_1, \dots, x_N$ 已知。证明 θ 的最大似然估计量为

$$\hat{\theta} = \frac{\sum_{i=1}^N n_i}{\sum_{i=1}^N a(x_i)}.$$

证明 $\hat{\theta}$ 为无偏的, 并且其方差由最小方差边界给出 (参见习题 6.6)。

解答:

对数似然为

$$\log L = \sum_{i=1}^N [n_i \log(\theta a_i) - \theta a_i - \log(n_i!)] .$$

对 θ 求导:

$$\frac{\partial \log L}{\partial \theta} = \sum_i \left(\frac{n_i}{\theta} - a_i \right) = 0.$$

因此

$$\hat{\theta} = \frac{\sum_i n_i}{\sum_i a_i}.$$

无偏性:

$$E[\hat{\theta}] = \frac{\sum_i E[n_i]}{\sum_i a_i} = \frac{\sum_i \theta a_i}{\sum_i a_i} = \theta.$$

方差:

$$V[\hat{\theta}] = \frac{\sum_i V[n_i]}{(\sum_i a_i)^2} = \frac{\theta \sum_i a_i}{(\sum_i a_i)^2} = \frac{\theta}{\sum_i a_i}.$$

Fisher 信息为

$$I(\theta) = \frac{\sum_i a_i}{\theta},$$

故 CRLB 为 $\theta / \sum_i a_i$, 恰好达到下界。

10. 第 6 章第 9 题描述的状况的例子之一为(反)中微子-核子散射。根据夸克-部分子模型, 反应 $\nu N \rightarrow \mu^- X$ 和 $\bar{\nu} N \rightarrow \mu^+ X$ 的截面为

$$\sigma(\nu N \rightarrow \mu^- X) = \frac{G^2 M E}{\pi} \left(\langle q \rangle + \frac{1}{3} \langle \bar{q} \rangle \right) \equiv \theta_\nu E,$$

$$\sigma(\bar{\nu} N \rightarrow \mu^+ X) = \frac{G^2 M E}{\pi} \left(\frac{1}{3} \langle q \rangle + \langle \bar{q} \rangle \right) \equiv \theta_{\bar{\nu}} E.$$

其中 E 为入射(反)中微子的能量, $M = 0.938 \text{ GeV}$ 为靶核子的质量, $G = 1.16 \times 10^{-6} \text{ GeV}^{-2}$ 为费米常数(取自然单位制 $c = 1$)。这里变量 x 对应于能量 E , 式 (6.15) 右端的参数对应两个不同的参数 θ_ν 和 $\theta_{\bar{\nu}}$ 。假设在 N 个不同能量值处收集了数据。每个能量点, 事例数的期待值为

$$\nu_i = \sigma(E_i) \epsilon(E_i) L_i,$$

其中 $\sigma(E_i)$ 为(反)中微子在能量为 E_i 时的截面, L_i 为积分亮度, $\epsilon(E_i)$ 为记录事例的概率(效率), 效率通常为能量的函数。出于本习题的目的, 我们假设能量 E_i , 积分亮度 L_i 以及效率 $\epsilon(E_i)$ 精确已知没有不确定度。(再假设没有本底事例。) 确定参数 θ_ν 和 $\theta_{\bar{\nu}}$ 的最大似然估计量, 并据此求 $\langle q \rangle$ 和 $\langle \bar{q} \rangle$ 的估计量。在夸克-部分子模型中, 它们分别对应夸克和反夸克携带的动量占核子动量的份额。确定除了正反夸克外其它粒子(即, 胶子)携带的动量份额 $\langle g \rangle = 1 - \langle q \rangle - \langle \bar{q} \rangle$ 。

解答:

每个能量点的期望事例数可写为

$$\nu_i = \sigma(E_i) \epsilon_i L_i = \theta E_i \epsilon_i L_i.$$

令

$$a_i = E_i \epsilon_i L_i.$$

由第 6 章第 9 题, 若中微子和反中微子样本分别记为 $n_i^{(\nu)}$ 、 $n_i^{(\bar{\nu})}$, 则

$$\hat{\theta}_\nu = \frac{\sum_i n_i^{(\nu)}}{\sum_i E_i \epsilon_i^{(\nu)} L_i^{(\nu)}}, \quad \hat{\theta}_{\bar{\nu}} = \frac{\sum_i n_i^{(\bar{\nu})}}{\sum_i E_i \epsilon_i^{(\bar{\nu})} L_i^{(\bar{\nu})}}.$$

若两组数据的 E_i, ϵ_i, L_i 完全相同, 上式的分母才相同。

记

$$C = \frac{G^2 M}{\pi}.$$

题设给出

$$\theta_\nu = C \left(\langle q \rangle + \frac{1}{3} \langle \bar{q} \rangle \right), \quad \theta_{\bar{\nu}} = C \left(\frac{1}{3} \langle q \rangle + \langle \bar{q} \rangle \right).$$

解这个二元线性方程组, 得到

$$\langle q \rangle = \frac{3}{8C} (3\theta_\nu - \theta_{\bar{\nu}}) = \frac{3\pi}{8G^2 M} (3\theta_\nu - \theta_{\bar{\nu}}),$$

$$\langle \bar{q} \rangle = \frac{3}{8C} (3\theta_{\bar{\nu}} - \theta_\nu) = \frac{3\pi}{8G^2 M} (3\theta_{\bar{\nu}} - \theta_\nu).$$

把 θ 换成对应的 MLE 即得 $\langle q \rangle$ 和 $\langle \bar{q} \rangle$ 的估计量。最后

$$\langle g \rangle = 1 - \langle q \rangle - \langle \bar{q} \rangle.$$

11. 确定阿伏伽德罗常数的最早实验之一是基于布朗运动, 实验装置如图 6.1 所示。Jean Perrin 用该装置观测悬浮在水中的乳香(一种抛光材料)颗粒。




图 6.1: Perrin 实验中通过移动显微镜焦平面统计不同高度粒子数的示意图。

粒子为半径 $r = 0.52 \mu\text{m}$ 的球状颗粒，密度为 1.063 g/cm^3 ，即，比水的密度大 0.063 g/cm^3 。在显微镜中观测这些颗粒，只有大约 $1 \mu\text{m}$ 的一层在聚焦范围内，范围之外的粒子观测不到。通过调节显微镜的透镜，焦平面可以垂直移动。在 4 个不同高度 z 处拍摄了照片（最低高度任意设为 $z = 0$ ），并数出不同 z 处的粒子数 $n(z)$ 。数据如表 6.1 所示。

$z (\mu\text{m})$	0	6	12	18
粒子数 n	1880	940	530	305

表 6.1: Perrin 观测的数据，乳剂中不同高度 z 处乳香粒子的数目。

水中球状乳香粒子的引力势能为

$$E = \frac{4}{3}\pi r^3 \Delta \rho g z,$$

其中 $\Delta \rho = \rho_{\text{乳香}} - \rho_{\text{水}} = 0.063 \text{ g/cm}^3$ 为密度差， $g = 980 \text{ cm/s}^2$ 为重力加速度。统计力学预言，粒子处在能量为 E 的态的概率正比于

$$P(E) \propto e^{-E/kT},$$

其中 k 为 Boltzmann 常数， T 为绝对温度。因此，粒子数作为高度的函数服从指数规律，其中在 z 处观测到的粒子数 n 可以看作均值为 $\nu(z)$ 的泊松变量。结合式 (6.17) 和 (6.18) 得到

$$\nu(z) = \nu_0 \exp\left(-\frac{4\pi r^3 \Delta \rho g z}{3kT}\right),$$

其中 ν_0 为 $z = 0$ 时粒子数的期待值。

- (1) 写程序用最大似然法计算参数 k 和 ν_0 。利用表 6.1 中的数据按照泊松概率构造最大似然函数（参见《统计数据分析》6.10 节），

$$\log L(\nu_0, k) = \sum_{i=1}^N (n_i \log \nu_i - \nu_i),$$

其中 $N = 4$ 为测量次数。温度取 $T = 293 \text{ K}$ 。

(2) 利用得到的 k , 通过下面的关系计算阿伏伽德罗常数

$$N_A = R/k,$$

其中 R 为气体常数。Perrin 计算时取值为 $R = 8.32 \times 10^7 \text{ erg}/(\text{mol K})$ 。

(3) 不求解对数似然函数 (6.20) 的最大值, 而是通过最小化

$$\chi_P^2(\nu_0, k) = 2 \sum_{i=1}^N \left(n_i \log \frac{n_i}{\nu_i} + \nu_i - n_i \right),$$

其中 $\nu_i = \nu(z_i)$ 通过式 (6.19) 依赖于 ν_0 和 k 。利用 χ_P^2 的值计算拟合优度 (参见《统计数据分析》6.11 节)。讨论 Perrin 测量 N_A 中可能的系统不确定度。

解答:

题目给出

$$\nu(z) = \nu_0 \exp \left(-\frac{4\pi r^3 \Delta \rho g z}{3kT} \right),$$

其中 $z = 0, 6, 12, 18 \mu\text{m}$ 处观测到的计数分别是

$$1880, 940, 530, 305.$$

(1) 最大似然估计

把不同高度的计数视为独立泊松变量, 似然函数为

$$\log L(\nu_0, k) = \sum_{i=1}^4 (n_i \log \nu_i - \nu_i) + \text{const.}$$

程序对 (ν_0, k) 做数值极大化, 得到

$$\hat{\nu}_0 \approx 1.846 \times 10^3, \quad \hat{k} \approx 1.20 \times 10^{-16} \text{ erg/K.}$$

(2) 阿伏伽德罗常数

由

$$N_A = \frac{R}{k}, \quad R = 8.32 \times 10^7 \text{ erg}/(\text{mol K}),$$

得到

$$\hat{N}_A \approx 6.95 \times 10^{23} \text{ mol}^{-1}.$$

(3) Pearson 似然卡方


定义

$$\chi_P^2 = 2 \sum_i \left(n_i \log \frac{n_i}{\nu_i} + \nu_i - n_i \right).$$

把极大似然点代入, 得到大约

$$\chi_P^2 \approx 4.59.$$

如果按 4 个数据点减去 2 个拟合参数, 取自由度约为 2, 则得到一个中等大小的 p 值, 说明拟合并不差, 但样本点非常少, 结论仍受系统误差影响。



Perrin 计数数据与泊松最大似然指数模型的拟合结果。

- 颗粒半径 r 的标定误差；
- 实际可见焦深不一定严格为常数；
- 焦平面高度 z 的刻度误差；
- 温度、密度差 $\Delta\rho$ 的不确定性；
- 计数之间未必完全独立泊松。

实验物理中的统计方法

第 7 章最小二乘法

1. Galileo 研究运动的实验之一是小球和斜坡的实验。在离开斜坡边缘之前，小球的轨迹变成水平，如图 7.1 所示。对于不同的高度 h ，测量从斜坡边缘到落地点的水平距离 d 。1608 年，Galileo 测量了 5 组数据，如表 7.1 所示。假设高度 h 的误差可以忽略，水平距离 d 可以看做独立的标准差 $\sigma = 15$ punti 的高斯随机变量。（实际上我们不清楚 Galileo 如何估计测量误差，但是 1-2% 的误差是可以接受的。）此外，我们知道如果 $h = 0$ ，则水平距离 d 将为零，即，如果球从斜坡边缘出发，它将垂直落到地上。




图 7.1: Galileo 斜坡实验的几何关系示意图。

h (punti)	1000	828	800	600	300
d (punti)	1500	1340	1328	1172	800

表 7.1: Galileo 斜坡实验的 5 组数据。给定初始高度 h ， d 为落地前的水平距离。单位为 punti，1 punto $\simeq 1$ mm。

- (1) 考虑 h 和 d 的关系为如下形式

$$d = \alpha h$$

以及

$$d = \alpha h + \beta h^2.$$

求参数 α 和 β 的最小二乘估计量。对应于这两个假设的最小 χ^2 和 P -值分别为多少？

- (2) 假设 d 和 h 的关系为如下形式

$$d = \alpha h^\beta.$$

写一段程序对 α 和 β 进行最小二乘拟合。注意这是参数的非线性函数，必须数值求解。

- (3) Galileo 认为运动是水平分量和垂直分量的叠加，其中水平运动是匀速运动，垂直速度在斜坡的最低处为零，随后随时间线性增加。证明这将导致关系式

$$d = \alpha\sqrt{h}.$$

求 α 的最小二乘估计量以及最小 χ^2 。该假设的 P -值是多少？

解答：

把数据记为

$$(h_i, d_i) = (1000, 1500), (828, 1340), (800, 1328), (600, 1172), (300, 800),$$

并把各 d_i 视作标准差为 $\sigma = 15$ punti 的独立高斯变量。

(1) 比较模型

(a) 线性模型

$$d = \alpha h.$$

加权最小二乘等价于最小化

$$\chi^2(\alpha) = \sum_i \frac{(d_i - \alpha h_i)^2}{\sigma^2}.$$

令导数为零，得到

$$\hat{\alpha} = \frac{\sum_i h_i d_i}{\sum_i h_i^2}.$$

(b) 二次模型

$$d = \alpha h + \beta h^2.$$

这是线性参数模型，可直接由正规方程或矩阵最小二乘求出 $(\hat{\alpha}, \hat{\beta})$ 。

程序计算结果：

- $d = \alpha h$:

$$\hat{\alpha} = 1.662756, \quad \chi_{\min}^2 = 661.99, \quad n_{\text{dof}} = 4, \quad P \approx 5.9 \times 10^{-142}.$$

- $d = \alpha h + \beta h^2$:

$$\hat{\alpha} = 2.792921, \quad \hat{\beta} = -1.35055 \times 10^{-3},$$

$$\chi_{\min}^2 = 64.74, \quad n_{\text{dof}} = 3, \quad P \approx 5.7 \times 10^{-14}.$$

这说明如果坚持把误差取为 15 punti，那么前两个模型都拟合得很差。

(2) 幂律模型

设

$$d = \alpha h^\beta.$$

这是非线性参数拟合。程序数值最小化得到

$$\hat{\alpha} = 43.7606, \quad \hat{\beta} = 0.511056,$$

$$\chi_{\min}^2 = 3.756, \quad n_{\text{dof}} = 3, \quad P = 0.289.$$

这已经是接受的拟合。

(3) Galileo 的平方根模型

由 Galileo 的运动学推导可得

$$d = \alpha\sqrt{h}.$$


最小二乘估计为

$$\hat{\alpha} = \frac{\sum_i d_i \sqrt{h_i}}{\sum_i h_i}.$$

数值结果:

$$\hat{\alpha} = 47.0858, \quad \chi_{\min}^2 = 4.208, \quad n_{\text{dof}} = 4, \quad P = 0.379.$$

因此在这组数据上, $d \propto \sqrt{h}$ 的物理模型优于简单线性模型, 也优于随意加入 h^2 项后的二次模型。它与幂律模型得到的 $\beta \approx 0.51$ 彼此一致。



Galileo 数据及平方根模型、一般幂律模型的拟合曲线。

2. 考虑对直方图的最小二乘拟合。直方图对应区间 $i = 1, \dots, N$ 的事例数为 y_i , 理论预言值为

$$\lambda_i(\theta) = n \int_{x_i^{\min}}^{x_i^{\max}} f(x; \theta) dx,$$

其中 $f(x; \theta)$ 依赖于未知参数 θ 。假设用参数 ν 代替总事例数 n , 并且该参数在最小化

$$\chi^2(\theta, \nu) = \sum_{i=1}^N \frac{(y_i - \lambda_i(\theta, \nu))^2}{\sigma_i^2}$$

时与其它参数同时调整。

(1) 证明如果 $\sigma_i^2 = \lambda_i$, 则总事例数的估计量为

$$\hat{\nu}_{\text{LS}} = n + \frac{\chi_{\min}^2}{2}.$$

(2) 证明如果 $\sigma_i^2 = y_i$ (修正后的最小二乘), 则估计量为

$$\hat{\nu}_{\text{MLS}} = n - \chi_{\min}^2.$$

解答：

若第 i 个 bin 的理论期望写作

$$\lambda_i(\theta, \nu) = \nu \int_{x_i^{\min}}^{x_i^{\max}} f(x; \theta) dx,$$

并把总归一化参数也一并发进拟合，那么：

- (1) 当取 $\sigma_i^2 = \lambda_i$ 时
最小化

$$\chi^2(\theta, \nu) = \sum_i \frac{(y_i - \lambda_i)^2}{\lambda_i}$$

对 ν 求导可得

$$\hat{\nu}_{LS} = n + \frac{\chi_{\min}^2}{2}.$$

因此普通 LS 会把总事件数估高。

- (2) 当取 $\sigma_i^2 = y_i$ 时
最小化

$$\chi^2(\theta, \nu) = \sum_i \frac{(y_i - \lambda_i)^2}{y_i}$$

则有

$$\hat{\nu}_{MLS} = n - \chi_{\min}^2.$$

所以修正最小二乘会把总事件数估低。

这两个结果本质上都来自“把分母里的方差也当成与待估参数有关”后，目标函数和真正的对数似然不再一致。

3. 考虑对直方图的最小二乘拟合，第 i 个区间的事例数为 y_i ， $i = 1, \dots, N$ ，对应的期待值为 $\lambda_i(\theta)$ 。假设总事例数 n 可以看作常数，于是 y_i 服从多项分布。

- (1) 求协方差矩阵 $V_{ij} = \text{cov}[y_i, y_j]$ 。为什么该矩阵的逆不存在？
(2) 考虑只使用前 $N - 1$ 个区间进行拟合。求协方差矩阵的逆，并证明这等价于对所有 N 个区间进行拟合但不考虑相关性。

解答：

设总事件数固定为 n ，各 bin 概率为 p_i ，故 $y = (y_1, \dots, y_N) \sim \text{Multinomial}(n; p_1, \dots, p_N)$ 。

- (1) 协方差矩阵为

$$V_{ij} = \text{cov}(y_i, y_j) = np_i(\delta_{ij} - p_j).$$

即

$$V_{ii} = np_i(1 - p_i), \quad V_{ij} = -np_i p_j \quad (i \neq j).$$

该矩阵不可逆，因为总数固定给出严格约束

$$\sum_{i=1}^N y_i = n.$$

于是 $\sum_i (y_i - \mathbb{E}[y_i]) = 0$ ，存在一个零方差方向，矩阵秩至多为 $N - 1$ 。

- (2) 只取前 $N - 1$ 个 bin。令 $p_N = 1 - \sum_{i=1}^{N-1} p_i$ ，则前 $N - 1$ 个 bin 的协方差矩阵为

$$V = n(D - pp^T), \quad D = \text{diag}(p_1, \dots, p_{N-1}).$$

用 Sherman–Morrison 公式得

$$(V^{-1})_{ij} = \frac{1}{n} \left(\frac{\delta_{ij}}{p_i} + \frac{1}{p_N} \right), \quad i, j = 1, \dots, N-1.$$

设残差 $r_i = y_i - np_i$ 。由于总数固定, $r_N = -\sum_{i=1}^{N-1} r_i$ 。于是相关协方差给出的二次型为

$$\sum_{i,j=1}^{N-1} r_i (V^{-1})_{ij} r_j = \sum_{i=1}^{N-1} \frac{r_i^2}{np_i} + \frac{(\sum_{i=1}^{N-1} r_i)^2}{np_N} = \sum_{i=1}^N \frac{r_i^2}{np_i}.$$

这正是使用全部 N 个 bin、但只取对角方差 $\sigma_i^2 = np_i$ 时的 Pearson χ^2 。因此二者等价。

4. 假设样本容量为 n , 利用该样本得到 N 个量的测量值: $y_1, \dots, y_N$ 。这 N 个测量值将被用于最小二乘拟合以估计若干未知参数。如果这 N 个测量是相关的, 在构造 χ^2 时需要用到协方差矩阵的逆 V^{-1} 。一般来说, 我们先通过某种办法 (比如蒙特卡罗计算) 得到相关系数矩阵 $\rho_{ij} = V_{ij}/(\sigma_i \sigma_j)$ (其中 $i, j = 1, 2, \dots, N$), 然后再计算得到协方差矩阵的逆。

- (1) 注意到对于有效估计量, 协方差矩阵的逆正比于样本容量 n 。证明: 在此条件下, 相关系数矩阵与样本容量 n 无关。
- (2) 证明协方差矩阵的逆为

$$(V^{-1})_{ij} = \frac{(\rho^{-1})_{ij}}{\sigma_i \sigma_j}.$$

【提示: 从下面等式出发

$$\delta_{ij} = \sum_k (V^{-1})_{ik} V_{kj} = \sum_k (V^{-1})_{ik} \rho_{kj} \sigma_k \sigma_j$$

对式 (7.10) 两边都乘以 ρ^{-1} , 并对适当的指标求和即可得到式 (7.9)。】

解答:

若协方差矩阵写成

$$V_{ij} = \rho_{ij} \sigma_i \sigma_j,$$

其中 ρ 是相关系数矩阵, 则

- (1) 若估计量是有效的
通常 $V \propto 1/n$ 。于是 $\sigma_i \propto n^{-1/2}$, 而

$$\rho_{ij} = \frac{V_{ij}}{\sigma_i \sigma_j}$$

中的 n 因子完全约去, 因此 ρ 与样本量 n 无关。

- (2) 证明逆矩阵
记 $D = \text{diag}(\sigma_1, \dots, \sigma_N)$, 则

$$V = D \rho D.$$

因此

$$V^{-1} = D^{-1} \rho^{-1} D^{-1},$$

即

$$(V^{-1})_{ij} = \frac{(\rho^{-1})_{ij}}{\sigma_i \sigma_j}.$$

5. 考虑随机变量 x 的两个部分重叠的样本，它们的样本容量分别为 n 和 m ，共有部分的样本容量为 c 。假设已知 x 的方差 $V[x] = \sigma^2$ 。考虑样本均值

$$y_1 = \frac{1}{n} \sum_{i=1}^n x_i$$

和

$$y_2 = \frac{1}{m} \sum_{i=1}^m x_i.$$

- (1) 证明协方差为

$$\text{cov}[y_1, y_2] = \frac{c\sigma^2}{nm}.$$

- (2) 利用 7.6 节的结果，求 y_1 和 y_2 的加权平均和方差。

解答：

两个样本均值为

$$y_1 = \frac{1}{n} \sum_{i=1}^n x_i, \quad y_2 = \frac{1}{m} \sum_{j=1}^m x_j.$$

只有共有的 c 个观测会同时出现在两个求和中，因此

$$\text{cov}(y_1, y_2) = \frac{1}{nm} c\sigma^2 = \frac{c\sigma^2}{nm}.$$

并且

$$V[y_1] = \frac{\sigma^2}{n}, \quad V[y_2] = \frac{\sigma^2}{m}.$$

于是

$$V = \sigma^2 \begin{pmatrix} 1/n & c/(nm) \\ c/(nm) & 1/m \end{pmatrix}.$$

对同一真均值 μ 的两个相关估计量，最佳线性无偏组合为

$$\hat{\mu} = \frac{\mathbf{1}^T V^{-1} \mathbf{y}}{\mathbf{1}^T V^{-1} \mathbf{1}}.$$

代入上面的 V 并化简，得到

$$\hat{\mu} = \frac{(n-c)y_1 + (m-c)y_2}{n+m-2c}.$$

其方差为

$$V[\hat{\mu}] = \frac{1}{\mathbf{1}^T V^{-1} \mathbf{1}} = \sigma^2 \frac{nm - c^2}{nm(n+m-2c)}.$$

检查两个极限：若 $c = 0$ ，则 $\hat{\mu} = (ny_1 + my_2)/(n+m)$ ，方差为 $\sigma^2/(n+m)$ ；若第一个样本完全包含在第二个样本中 ($c = n < m$)，则 $\hat{\mu} = y_2$ ，方差为 σ^2/m 。

6. 天文学家托勒密 (Claudius Ptolemy) 利用圆盘做过光折射的实验。他把圆盘的一半浸入水中，圆心正好位于水面处，如图 7.2 所示。大约公元 140 年，Ptolemy 对 8 组不同的入射角 θ_i 测量了相应的折射角 θ_r ，结果如表 7.2 所示。本练习中，我们认为入射角已知且误差可以忽略，而把折射角看作标准差为 $\sigma = \frac{1}{2}^\circ$ 的高斯随机变量。（这是一个合理的假设，记录的角度精确到最邻近的半度。注意，我们可以将 θ_i 的误差吸收到 θ_r 的有效误差中。）




图 7.2: Ptolemy 折射实验的角度定义示意图。

θ_i (°)	10	20	30	40	50	60	70	80
θ_r (°)	8	$15\frac{1}{2}$	$22\frac{1}{2}$	29	35	$40\frac{1}{2}$	$45\frac{1}{2}$	50

表 7.2: Ptolemy 折射实验的入射角和折射角，单位均为度。

(1) 直到 17 世纪才发现正确的折射定律，在此之前，通常的假设是

$$\theta_r = \alpha \theta_i,$$

然而 Ptolemy 更喜欢用下面的形式

$$\theta_r = \alpha \theta_i - \beta \theta_i^2.$$

对这两种不同的假设，求参数的最小二乘估计量，并计算最小 χ^2 值。评论一下两个假设的拟合优度。是否可以相信所有的数据都是从实际测量得来的？

(2) 1621 年 Snell 发现了折射定律

$$\theta_r = \sin^{-1} \left(\frac{\sin \theta_i}{r} \right),$$

其中 $r = n_r/n_i$ 为两种介质的折射率之比。求 r 的最小二乘估计量并计算出最小 χ^2 值。评价对 θ_r 作 $\sigma = \frac{1}{2}^\circ$ 假设的合理性。

解答：

数据为

$$(\theta_i, \theta_r) = (10, 8), (20, 15.5), (30, 22.5), (40, 29), (50, 35), (60, 40.5), (70, 45.5), (80, 50),$$

且把 θ_r 看作标准差为 $\sigma = 0.5^\circ$ 的高斯变量。

(1) 经验模型比较

(a) 线性模型

$$\theta_r = \alpha \theta_i.$$

得到

$$\hat{\alpha} = 0.666176, \quad \chi_{\min}^2 = 134.65, \quad n_{\text{dof}} = 7, \quad P \approx 6.7 \times 10^{-26}.$$

(b) Ptolemy 喜欢的经验式

$$\theta_r = \alpha \theta_i - \beta \theta_i^2.$$

得到

$$\hat{\alpha} = 0.825000, \quad \hat{\beta} = 2.5000 \times 10^{-3},$$

$$\chi_{\min}^2 \approx 0, \quad n_{\text{dof}} = 6, \quad P \approx 1.$$

这个结果看上去“好得过头”，更像是数据本身被这种简单经验式近似生成或已经经过明显取整；因此不能机械地把 $P = 1$ 理解为“模型绝对正确”。

(2) Snell 定律


设

$$\theta_r = \sin^{-1} \left(\frac{\sin \theta_i}{r} \right),$$

其中 $r = n_r/n_i$ 。数值最小化得到

$$\hat{r} = 1.31162, \quad \chi_{\min}^2 = 14.00, \quad n_{\text{dof}} = 7, \quad P = 0.0511.$$

这已经接近通常的可接受边界，而且 $r \approx 1.31$ 对空气-水界面是很合理的数值。若把 $\sigma = 0.5^\circ$ 看作记录精度给出的“有效标准差”，那么 Snell 定律的拟合并不差。



Ptolemy 折射数据及线性、二次经验式、Snell 定律拟合。

7. 重新考虑练习 6.9: N 个独立的泊松变量 $n = (n_1, \dots, n_N)$, 均值为 $\nu = (\nu_1, \dots, \nu_N)$, 其中均值与某控制变量 x 有关,

$$\nu(x) = \theta a(x).$$

(1) 首先考虑最小二乘方法 (LS), χ^2 的分母使用 $\sigma_i^2 = \nu_i$ 。证明 θ 的最小二乘估计量为

$$\hat{\theta} = \left(\frac{\sum_{i=1}^N n_i^2}{\sum_{i=1}^N a(x_i)} \right)^{1/2}.$$

通过对 $\hat{\theta}(n)$ 在 ν 处进行泰勒展开至第二阶, 计算期待值, 证明 (7.18) 的偏置为

$$b = \frac{N-1}{2 \sum_{i=1}^N a(x_i)} + O(E[(n_i - \nu_i)^3]).$$

(利用独立泊松变量的协方差 $\text{cov}[n_i, n_j] = \delta_{ij}\nu_j$.)

- (2) 取 χ^2 的分母为 $\sigma_i^2 = n_i$, 即把观测值作为方差, 用修正的最小二乘法 (MLS) 重复 (a) 中的步骤. 证明 θ 的最小二乘估计量为

$$\hat{\theta} = \frac{\sum_{i=1}^N a(x_i)}{\sum_{i=1}^N a(x_i)^2/n_i},$$

并且偏置为

$$b = -\frac{N-1}{\sum_{i=1}^N a(x_i)} + O(E[(n_i - \nu_i)^3]).$$

将 (a) 和 (b) 得到的偏置与本章第 2 题进行比较。

(c) 利用误差传递, 对 LS 和 MLS 两种情况估计 $\hat{\theta}$ 的方差。

注意, 由于习题 (6.9) 已经证明了 θ 的最大似然估计量是无偏的并且方差最小, 这里并不推荐最小二乘 (LS) 和修正的最小二乘 (MLS) 估计量。然而, 对于足够大的数据样本, 三个方法是类似的, 参见习题 (7.8)。

解答:

设 $a_i = a(x_i)$, $n_i \sim \text{Pois}(\nu_i)$, 且 $\nu_i = \theta a_i$ 。

- (1) LS: $\sigma_i^2 = \nu_i = \theta a_i$
最小化

$$\chi_{LS}^2 = \sum_i \frac{(n_i - \theta a_i)^2}{\theta a_i} = \sum_i \left(\frac{n_i^2}{\theta a_i} - 2n_i + \theta a_i \right).$$

对 θ 求导并令零, 得到

$$\hat{\theta}_{LS} = \left(\frac{\sum_i n_i^2/a_i}{\sum_i a_i} \right)^{1/2}.$$

按一般的 $\nu_i = \theta a_i$ 情形, n_i^2 项必须带有权重 $1/a_i$; 在所有 $a_i = 1$ 时才化为不含 a_i 的形式。在 $n_i = \nu_i$ 附近二阶展开, 利用 $\text{cov}(n_i, n_j) = \delta_{ij}\nu_i$, 可得

$$b_{LS} = E[\hat{\theta}_{LS}] - \theta = \frac{N-1}{2 \sum_i a_i} + O(E[(n_i - \nu_i)^3]).$$

所以普通 LS 有正偏。

- (2) MLS: $\sigma_i^2 = n_i$
最小化

$$\chi_{MLS}^2 = \sum_i \frac{(n_i - \theta a_i)^2}{n_i} = \sum_i \left(n_i - 2\theta a_i + \frac{\theta^2 a_i^2}{n_i} \right).$$

对 θ 求导得

$$\hat{\theta}_{MLS} = \frac{\sum_i a_i}{\sum_i a_i^2/n_i}.$$

同样在 $n_i = \nu_i$ 附近展开, 得到

$$b_{MLS} = -\frac{N-1}{\sum_i a_i} + O(E[(n_i - \nu_i)^3]).$$

因此 MLS 有负偏，且一阶偏置大小约为 LS 的两倍。

(3) 方差

对两种估计量在 $n_i = \nu_i$ 处作一阶误差传播，都有

$$\left. \frac{\partial \hat{\theta}}{\partial n_i} \right|_{n=\nu} = \frac{1}{\sum_j a_j}.$$

于是

$$V[\hat{\theta}] \approx \sum_i \left(\frac{1}{\sum_j a_j} \right)^2 V[n_i] = \frac{\theta}{\sum_i a_i}.$$

这与第 6.9 题的 MLE 方差相同只是大样本一阶近似；有限样本下 LS 和 MLS 仍分别有上述偏置，因此泊松问题中更推荐直接使用最大似然估计量

$$\hat{\theta}_{MLE} = \frac{\sum_i n_i}{\sum_i a_i}.$$

8. 重新考虑 Perrin 关于乳香粒子作为高度的函数（第 6 章第 11 题）。通过最小化

$$\chi^2(k, \nu_0) = \sum_{i=1}^N \frac{(n_i - \nu_i(k, \nu_0))^2}{\sigma_i^2},$$

求玻尔兹曼常数 k （或者等价于阿伏伽德罗常数 $N_A = R/k$ ）和系数 ν_0 的最小二乘估计量。

(1) 取 n_i 的标准差 σ_i 为 $\sqrt{\nu_i}$ （通常的最小二乘法）。

(2) 取 σ_i 为 $\sqrt{n_i}$ （修正的最小二乘法）。

将 (a) 和 (b) 得到的估计量与习题 (6.11) 中最大似然估计量进行比较。

解答：

沿用 6.11 的 Perrin 数据：

$$(z, n) = (0, 1880), (6, 940), (12, 530), (18, 305),$$

理论模型为

$$\nu(z) = \nu_0 \exp \left[-\frac{4\pi r^3 \Delta \rho g z}{3kT} \right].$$

(1) 取 $\sigma_i = \sqrt{\nu_i}$
最小化

$$\chi^2(k, \nu_0) = \sum_i \frac{(n_i - \nu_i)^2}{\nu_i}$$

数值结果：

$$\hat{\nu}_0 = 1845.52, \quad \hat{k} = 1.19946 \times 10^{-16} \text{ erg/K}, \quad \hat{N}_A = \frac{R}{\hat{k}} = 6.936 \times 10^{23} \text{ mol}^{-1}.$$

并且

$$\chi_{\min}^2 = 4.569, \quad n_{\text{dof}} = 2, \quad P = 0.102.$$

(2) 取 $\sigma_i = \sqrt{n_i}$
最小化

$$\chi^2(k, \nu_0) = \sum_i \frac{(n_i - \nu_i)^2}{n_i}$$

得到

$$\hat{\nu}_0 = 1843.83, \quad \hat{k} = 1.19710 \times 10^{-16} \text{ erg/K}, \quad \hat{N}_A = 6.950 \times 10^{23} \text{ mol}^{-1},$$

$$\chi_{\min}^2 = 4.619, \quad P = 0.0993.$$

与第 6 章第 11 题的 MLE 比较。

MLE 给出

$$\hat{\nu}_0 = 1844.94, \quad \hat{k} = 1.19870 \times 10^{-16} \text{ erg/K}, \quad \hat{N}_A = 6.941 \times 10^{23} \text{ mol}^{-1}.$$

三种方法在这组数据上的中心值很接近；因为数据量虽少，但每个 bin 的计数较大，泊松分布已接近高斯近似。不过从原则上看，MLE 仍然更自然，因为它直接使用了泊松似然，而两种最小二乘都引入了额外的近似。

实验物理中的统计方法

第 8 章矩方法

1. 考虑服从高斯分布的随机变量 x ，均值 μ 和方差 σ^2 未知，并假设样本为 $x_1, \dots, x_n$ 。

- (1) 利用矩方法构造 μ 和 σ^2 的估计量。利用函数 $a_1 = x$, $a_2 = x^2$ ，使得期望值 $E[a_i(x)]$ 对应于 x 的一阶和二阶代数矩。
- (2) 计算 (a) 中得到的估计量 $\hat{\mu}$ 与 $\hat{\sigma}^2$ 的期望值。这两个估计量是否是无偏的？

解答：

设样本 $x_1, \dots, x_n$ 来自高斯分布 $N(\mu, \sigma^2)$ ，但这里我们不用最大似然，而用矩方法。

- (1) 构造 μ 与 σ^2 的矩估计量

$$a_1(x) = x, \quad a_2(x) = x^2.$$

理论矩为

$$E[x] = \mu, \quad E[x^2] = \mu^2 + \sigma^2.$$

样本矩为

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i, \quad \overline{x^2} = \frac{1}{n} \sum_{i=1}^n x_i^2.$$

令样本矩等于理论矩：

$$\hat{\mu} = \bar{x}, \quad \hat{\sigma}^2 = \overline{x^2} - \bar{x}^2.$$

也就是

$$\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2.$$

这正好与高斯模型下的方差 MLE 一致。

- (2) 期望值：是否无偏
显然

$$E[\hat{\mu}] = E[\bar{x}] = \mu,$$

因此 $\hat{\mu}$ 无偏。

对方差估计量，利用第五章结论

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$$

是 σ^2 的无偏估计，而

$$\hat{\sigma}^2 = \frac{n-1}{n} s^2,$$

所以

$$E[\hat{\sigma}^2] = \frac{n-1}{n} \sigma^2.$$

因此矩方法得到的 $\hat{\sigma}^2$ 不是无偏估计，它向下偏。

2. 考虑粒子反应中产生的 ρ^0 介子衰变为两个带电 π 介子 ($\pi^+\pi^-$)。衰变角定义为, 在 $\pi^+\pi^-$ 质心系中 π^+ 运动方向与 ρ 的原初方向的夹角, 见图 8.1。由于 ρ^0 的自旋为 1, π 介子的自旋为 0, 可以证明 $\cos\theta$ 的分布具有如下形式




图 8.1: $\rho^0 \rightarrow \pi^+\pi^-$ 衰变角定义示意图。

$$f(\cos\theta; \eta) = \frac{1}{2}(1 - \eta) + \frac{3}{2}\eta \cos^2\theta,$$

其中自旋排列参数 η 的取值范围为 $-\frac{1}{2} \leq \eta \leq 1$ 。

- (1) 假设某反应产生的 ρ^0 中, 测量到 n 个 $\cos\theta$ 值。利用矩方法, 取 $a = x^2$, 构造自旋排列参数的估计量 $\hat{\eta}$ 。为什么不能用 $a = x$ 构造估计量?
- (2) 计算 $\hat{\eta}$ 的期待值和方差。

解答:

定义 $x = \cos\theta$, 分布为

$$f(x; \eta) = \frac{1}{2}(1 - \eta) + \frac{3}{2}\eta x^2, \quad -1 \leq x \leq 1, \quad -\frac{1}{2} \leq \eta \leq 1.$$

- (1) 用矩方法构造 η 的估计量; 为何不能取 $a = x$
先计算一阶矩:

$$E[x] = \int_{-1}^1 x f(x; \eta) dx = 0.$$

这与 η 无关, 所以用 $a = x$ 不能区分不同的 η , 自然无法构造估计量。
于是取二阶矩 $a = x^2$ 。先算

$$E[x^2] = \int_{-1}^1 x^2 f(x; \eta) dx = \frac{1 - \eta}{2} \int_{-1}^1 x^2 dx + \frac{3\eta}{2} \int_{-1}^1 x^4 dx.$$

利用

$$\int_{-1}^1 x^2 dx = \frac{2}{3}, \quad \int_{-1}^1 x^4 dx = \frac{2}{5},$$

得到

$$E[x^2] = \frac{1-\eta}{3} + \frac{3\eta}{5} = \frac{5+4\eta}{15}.$$

令样本二阶矩

$$\overline{x^2} = \frac{1}{n} \sum_{i=1}^n x_i^2$$

等于理论矩，解出

$$\hat{\eta} = \frac{15\overline{x^2} - 5}{4}.$$

(2) 计算 $E[\hat{\eta}]$ 与 $V[\hat{\eta}]$
由构造直接知道

$$E[\hat{\eta}] = \eta,$$

因此它是无偏估计量。

接着要算方差。先求四阶矩：

$$E[x^4] = \frac{1-\eta}{2} \int_{-1}^1 x^4 dx + \frac{3\eta}{2} \int_{-1}^1 x^6 dx.$$

再用

$$\int_{-1}^1 x^6 dx = \frac{2}{7},$$

得到

$$E[x^4] = \frac{1-\eta}{5} + \frac{3\eta}{7} = \frac{7+8\eta}{35}.$$

于是


$$V(\overline{x^2}) = \frac{1}{n} (E[x^4] - E[x^2]^2).$$

而

$$\hat{\eta} = \frac{15}{4}\overline{x^2} - \frac{5}{4},$$

故

$$V[\hat{\eta}] = \left(\frac{15}{4}\right)^2 V(\overline{x^2}).$$



不同 η 下 $x = \cos \theta$ 的理论密度；对称性说明一阶矩恒为 0。

代入并化简后得到

$$V[\hat{\eta}] = \frac{-28\eta^2 + 20\eta + 35}{28n}.$$

实验物理中的统计方法

第 9 章统计误差、置信区间和极限

1. 假设估计量 $\hat{\theta}$ 服从高斯分布，高斯分布的参数分别为 $\hat{\theta}$ 的真值 θ 和标准偏差 $\sigma_{\hat{\theta}}$ 。假设 $\sigma_{\hat{\theta}}$ 已知。

(1) 画出定义置信带的函数 $u_{\alpha}(\theta)$ 和 $v_{\beta}(\theta)$ (参见 Statistical Data Analysis 第 9.2 节)。

(2) 证明置信水平为 $1 - \gamma$ 时参数 θ 的中心置信区间由下式给出

$$\left[\hat{\theta} - \sigma_{\hat{\theta}} \Phi^{-1}(1 - \gamma/2), \hat{\theta} + \sigma_{\hat{\theta}} \Phi^{-1}(1 - \gamma/2) \right],$$

其中 Φ^{-1} 是标准高斯分布的分位数。

解答：

设估计量 $\hat{\theta}$ 服从高斯分布，均值为真值 θ ，标准差为已知常数 $\sigma_{\hat{\theta}}$ 。

(1) 置信带函数

若以 $1 - \alpha$ 和 $1 - \beta$ 作为上下边界的置信带，则定义

$$P(\hat{\theta} \leq u_{\alpha}(\theta) | \theta) = 1 - \alpha, \quad P(\hat{\theta} \leq v_{\beta}(\theta) | \theta) = \beta.$$

由于

$$\frac{\hat{\theta} - \theta}{\sigma_{\hat{\theta}}} \sim N(0, 1),$$

故


$$u_{\alpha}(\theta) = \theta + \sigma_{\hat{\theta}} \Phi^{-1}(1 - \alpha), \quad v_{\beta}(\theta) = \theta + \sigma_{\hat{\theta}} \Phi^{-1}(\beta).$$

(2) 中心置信区间

对中心区间取 $\alpha = \beta = \gamma/2$ ，反演置信带后得到

$$\theta \in \left[\hat{\theta} - \sigma_{\hat{\theta}} \Phi^{-1}(1 - \gamma/2), \hat{\theta} + \sigma_{\hat{\theta}} \Phi^{-1}(1 - \gamma/2) \right].$$

这就是式 (9.1)。



已知标准差的高斯估计量置信带：反演横向截线得到参数区间。

2. 随机变量 x 服从均值为 ξ 的指数分布, 考虑对 x 的 n 次观测. 参数 ξ 的最大似然估计量 (见 Statistical Data Analysis (6.6) 式) 由下式给出

$$\hat{\xi} = \frac{1}{n} \sum_{i=1}^n x_i,$$

并且 $\hat{\xi}$ 的概率密度函数 (参见 Statistical Data Analysis (10.25) 式) 为

$$g(\hat{\xi}; \xi) = \frac{n^n}{(n-1)!} \frac{\hat{\xi}^{n-1}}{\xi^n} e^{-n\hat{\xi}/\xi}.$$

(1) 证明: 定义置信带的曲线 $u_\alpha(\xi)$ 和 $v_\beta(\xi)$ 为

$$\begin{aligned} u_\alpha(\xi) &= \frac{\xi}{2n} F_{\chi^2}^{-1}(1-\alpha; 2n), \\ v_\beta(\xi) &= \frac{\xi}{2n} F_{\chi^2}^{-1}(\beta; 2n), \end{aligned}$$

其中 $F_{\chi^2}^{-1}$ 为 χ^2 分布的分位数. 根据习题 2.6, χ^2 分布的累积分布可以与不完全伽马函数 $P(x, n)$ 联系起来:

$$F_{\chi^2}(2x; 2n) = P(x, n) \equiv \frac{1}{\Gamma(n)} \int_0^x e^{-t} t^{n-1} dt.$$

取 $\alpha = \beta = 0.159$, $n = 5$, 画出 $u_\alpha(\xi)$ 和 $v_\beta(\xi)$. (χ^2 分布的分位数可以从标准分布表中查出, 或者在 ROOT 中调用 `TMath::ChisquareQuantile(Double_t p, Double_t ndf)` 函数得到.)

(2) 求出置信区间 $[a, b]$ 作为估计值 $\hat{\xi}$ 、样本容量 n 以及置信水平 α 和 β 的函数. 假设估计值为 $\hat{\xi} = 1.0$, 在 $u_\alpha(\xi)$ 和 $v_\beta(\xi)$ 的图上画出该估计量的值. 取 $n = 5$, $\alpha = \beta = 0.159$, 计算 a 和 b . 将计算结果与估计值加减一倍标准差得到的区间进行比较.

解答:

设 x 服从均值为 ξ 的指数分布, 样本均值的 MLE 为

$$\hat{\xi} = \frac{1}{n} \sum_{i=1}^n x_i.$$

其密度为

$$g(\hat{\xi}; \xi) = \frac{n^n}{(n-1)!} \frac{\hat{\xi}^{n-1}}{\xi^n} e^{-n\hat{\xi}/\xi}.$$

(1) 置信带函数
注意到

$$\frac{2n\hat{\xi}}{\xi} \sim \chi_{2n}^2,$$

故若定义

$$P(\hat{\xi} \leq u_\alpha(\xi) | \xi) = 1 - \alpha, \quad P(\hat{\xi} \leq v_\beta(\xi) | \xi) = \beta,$$

则

$$\frac{2n u_\alpha(\xi)}{\xi} = F_{\chi^2}^{-1}(1-\alpha; 2n), \quad \frac{2n v_\beta(\xi)}{\xi} = F_{\chi^2}^{-1}(\beta; 2n).$$

因此

$$u_{\alpha}(\xi) = \frac{\xi}{2n} F_{\chi^2}^{-1}(1 - \alpha; 2n), \quad v_{\beta}(\xi) = \frac{\xi}{2n} F_{\chi^2}^{-1}(\beta; 2n).$$

(2) 反演区间

给定观测 $\hat{\xi}$, 反演后得到

$$a = \frac{2n\hat{\xi}}{F_{\chi^2}^{-1}(1 - \alpha; 2n)}, \quad b = \frac{2n\hat{\xi}}{F_{\chi^2}^{-1}(\beta; 2n)}.$$

题目给出 $\hat{\xi} = 1.0$, $n = 5$, $\alpha = \beta = 0.159$, 程序算得

$$[a, b] = [0.69845, 1.75902].$$


若直接用“大样本一倍标准差”近似, 因

$$\sigma_{\hat{\xi}} = \frac{\xi}{\sqrt{n}},$$

常见近似区间为

$$1 \pm \frac{1}{\sqrt{5}} = [0.5528, 1.4472].$$

可以看出精确区间明显不对称, 而高斯近似过于对称。



$n = 5$ 、 $\alpha = \beta = 0.159$ 时指数均值参数的置信带与 $\hat{\xi} = 1$ 的反演。

3. 证明二项分布的参数 p 的上限和下限为

$$p_{\text{lo}} = \frac{nF_F^{-1}[\alpha; 2n, 2(N - n + 1)]}{N - n + 1 + nF_F^{-1}[\alpha; 2n, 2(N - n + 1)]},$$

$$p_{\text{up}} = \frac{(n + 1)F_F^{-1}[1 - \beta; 2(n + 1), 2(N - n)]}{(N - n) + (n + 1)F_F^{-1}[1 - \beta; 2(n + 1), 2(N - n)]}.$$

其中上下限的置信水平分别为 $1 - \alpha$ 和 $1 - \beta$, n 为 N 次试验中成功的次数, F_F^{-1} 为 F 分布的分位数, 由 F 分布定义:

$$f(x; n_1, n_2) = \left(\frac{n_1}{n_2}\right)^{n_1/2} \frac{\Gamma\left(\frac{1}{2}(n_1 + n_2)\right)}{\Gamma\left(\frac{1}{2}n_1\right)\Gamma\left(\frac{1}{2}n_2\right)} x^{n_1/2-1} \left(1 + \frac{n_1}{n_2}x\right)^{-(n_1+n_2)/2},$$

其中 $x > 0$, 参数 n_1 和 n_2 为整数 (自由度)。利用二项分布累积分布函数与自由度为 $n_1 = 2(n+1)$ 和 $n_2 = 2(N-n)$ 的累积分布函数 $F_F(x)$ 的关系

$$\sum_{k=0}^n \frac{N!}{k!(N-k)!} p^k (1-p)^{N-k} = 1 - F_F \left[\frac{(N-n)p}{(n+1)(1-p)}; 2(n+1), 2(N-n) \right].$$

F 分布的分位数可以从标准分布表中查得, 或者调用 ROOT 中的函数计算。

解答:

二项分布参数 p 的精确区间来自对二项分布尾概率的反演。对观测到 n 个成功、总试验数为 N 的情形, 下限 p_{lo} 由

$$P(X \geq n | p_{\text{lo}}) = 1 - \sum_{k=0}^{n-1} \binom{N}{k} p_{\text{lo}}^k (1-p_{\text{lo}})^{N-k} = 1 - \alpha$$

等价地给出; 上限 p_{up} 由

$$P(X \leq n | p_{\text{up}}) = 1 - \beta$$

给出。利用二项尾概率与 F 分布累积分布之间的恒等式, 可以把这两个反演方程写成 F 分布分位数的形式。

具体地, 二项分布的 Clopper-Pearson 区间也可写成 Beta 分布分位数

$$p_{\text{lo}} = B^{-1}(\alpha; n, N-n+1), \quad p_{\text{up}} = B^{-1}(1-\beta; n+1, N-n),$$

其中端点情形 $n=0$ 或 $n=N$ 需按极限理解。利用 Beta 分布与 F 分布分位数的关系

$$B^{-1}(q; a, b) = \frac{aF_F^{-1}(q; 2a, 2b)}{b + aF_F^{-1}(q; 2a, 2b)},$$

分别取 $(a, b) = (n, N-n+1)$ 和 $(a, b) = (n+1, N-n)$, 即得

$$p_{\text{lo}} = \frac{nF_F^{-1}[\alpha; 2n, 2(N-n+1)]}{N-n+1 + nF_F^{-1}[\alpha; 2n, 2(N-n+1)]},$$

$$p_{\text{up}} = \frac{(n+1)F_F^{-1}[1-\beta; 2(n+1), 2(N-n)]}{(N-n) + (n+1)F_F^{-1}[1-\beta; 2(n+1), 2(N-n)]}.$$

这就是题目要求证明的上下限公式。

4. 在 CERN 的 Gargamelle 气室中进行了反中微子-核子散射实验。选择的事例是只产生强子的事例 (通过中性流过程 $\bar{\nu}_\mu N \rightarrow \bar{\nu}_\mu X$), 或者是产生强子和一个 μ 子的事例 (通过带电流过程 $\bar{\nu}_\mu N \rightarrow \mu^+ X$)。从 212 个事例样本中, 64 个事例归类为中性流 (NC) 过程, 148 个归类为带电流 (CC) 过程。估计事例为中性流 (NC) 的概率, 并求出 68.3% 的中心置信区间。求 NC 与 CC 过程概率之比的估计量和置信区间。

解答:

样本中共有 212 个事件, 其中 64 个是 NC, 148 个是 CC, 因此

$$\hat{p} = \frac{64}{212} = 0.301887.$$

按 68.3% 中心精确区间 (Clopper-Pearson) 计算, 程序得到

$$p \in [0.26906, 0.33672].$$

NC 与 CC 概率之比为

$$r = \frac{p}{1-p}.$$

其 MLE 为

$$\hat{r} = \frac{64}{148} = 0.43243.$$

因为 $r(p) = p/(1-p)$ 是单调函数，区间可直接变换：

$$r \in \left[\frac{p_{\text{lo}}}{1-p_{\text{lo}}}, \frac{p_{\text{up}}}{1-p_{\text{up}}} \right] = [0.36810, 0.50766].$$

5. 在研究粒子碰撞的实验中，选择出来 10 个某种类型的事例，比如说某个量 x 具有较高值的事例。这 10 个高 x 值的事例中，发现有 2 个事例包含 μ 子。

- (1) 高 x 值事例中包含 μ 子的事例数目服从二项分布，求参数 p 的 68.3% 中心置信区间。将结果表示为 $p = \hat{p}_{-c}^{+d}$ ，其中 $\hat{p}$ 为 p 的最大似然估计， $[\hat{p}-c, \hat{p}+d]$ 为置信区间。
- (2) 将 (a) 中的区间与 $\hat{p} \pm \hat{\sigma}_{\hat{p}}$ 进行比较，其中 $\hat{\sigma}_{\hat{p}}$ 为 $\hat{p}$ 的标准偏差的估计量。
- (3) 经常犯的错误是将高 x 值的事例数 10 当作随机变量，并将其方差引入 $\hat{p}$ 的误差中（例如通过误差传递）。为什么这种方法是不正确的？

解答：

- (1) 精确中心区间

这里样本容量固定为 10，所以

$$n \sim \text{Binom}(10, p), \quad \hat{p} = \frac{2}{10} = 0.2.$$

取 68.3% 中心区间，即两侧尾概率各约为 $(1 - 0.683)/2 = 0.1585$ 。Clopper-Pearson 精确区间为

$$p \in [0.07191, 0.40555].$$

写成 $p = \hat{p}_{-c}^{+d}$ ，有

$$c = 0.2 - 0.07191 = 0.12809, \quad d = 0.40555 - 0.2 = 0.20555.$$

- (2) 与 $\hat{p} \pm \hat{\sigma}_{\hat{p}}$ 比较
大样本近似为

$$\hat{\sigma}_{\hat{p}} = \sqrt{\frac{\hat{p}(1-\hat{p})}{N}}.$$

代入 $\hat{p} = 0.2$ 、 $N = 10$ ：

$$\hat{\sigma}_{\hat{p}} = \sqrt{\frac{0.2 \times 0.8}{10}} = 0.12649.$$

故

$$\hat{p} \pm \hat{\sigma}_{\hat{p}} = [0.07351, 0.32649].$$

精确区间明显不对称；简单 $\pm 1\sigma$ 近似把上误差低估得较多。

- (3) 为什么不能把 10 也当随机量传播误差

题目条件是“先选出 10 个高 x 事例”，再在这 10 个事例中数含 μ 子的个数。也就是说，正确模型是条件在固定样本容量 $N = 10$ 下的二项分布。若再给 $N = 10$ 加上泊松或其它波动，就相当于改成了另一个无条件实验模型，会把“高 x 总率的不确定性”错误地混入“给定高 x 后含 μ 的条件概率”中。

6. 假设为了产生习题 (9.5) 中的事例，收集的总数据对应于积分亮度为 $L = 1 \text{ pb}^{-1}$ （误差可以忽略）。产生的给定类型事例总数可以看作均值为 $\nu = \sigma L$ 的泊松随机变量 n ，其中 σ 为产生截面。（为什么是泊松

分布?)

- (1) 对于高 x 值事例以及高 x 值的 μ 子事例, 假设观测到的事例数分别为 $n_x = 10$ 和 $n_{x\mu} = 2$, 求事例数期待值 ν_x 和 $\nu_{x\mu}$ 的 68.3% 中心置信区间。对应的产生截面 σ_x 和 $\sigma_{x\mu}$ 的置信区间为多少?
- (2) 将 (a) 中得到的置信区间与通过加减一倍标准偏差得到的区间进行比较。
- (3) 假设另外一个实验的积分亮度为 $L' = 100 \text{ pb}^{-1}$, 观测到 n'_x 个高 x 值的事例。但是这个实验不能鉴别 μ 子。利用数据 n_x , $n_{x\mu}$ 和 n'_x 构造参数 σ_x 和 $\sigma_{x\mu}/\sigma_x$ 的对数似然函数。证明 p 的最大似然估计量与 n'_x 无关。这是否说明第二个实验的结果对 p 的估计没有影响?
- (4) 假设最初的实验没有测量高 x 值的事例数, 只是测得了包含 μ 子的高 x 值事例数。利用结果 $n_{x\mu} = 2$ 和 n'_x , 构造 σ_x 和 p 的对数似然函数, 并求出最大似然估计量。利用误差传递估计 $\hat{p}$ 的标准偏差, 并比较区间 $\hat{p} \pm \sigma_{\hat{p}}$ 与习题 (9.5) 中
 - (a) 和 (b) 得到的区间。选作: 这种情况下, 如何构造 p 的置信区间?

解答:

设 $L = 1 \text{ pb}^{-1}$, 观测到

$$n_x = 10, \quad n_{x\mu} = 2.$$

事例计数来自稀有独立碰撞, 在固定积分亮度下可视为泊松变量, 因此

$$n_x \sim \text{Pois}(\nu_x), \quad n_{x\mu} \sim \text{Pois}(\nu_{x\mu}),$$

其中 $\nu_x = \sigma_x L$ 、 $\nu_{x\mu} = \sigma_{x\mu} L$ 。

- (1) 泊松均值和截面的精确区间

泊松均值 ν 的中心区间可由 χ^2 分位数给出:

$$\nu_{\text{lo}} = \frac{1}{2} F_{\chi^2}^{-1}(\alpha/2; 2n), \quad \nu_{\text{up}} = \frac{1}{2} F_{\chi^2}^{-1}(1 - \alpha/2; 2(n+1)),$$

其中 $\alpha = 1 - 0.683$ 。代入得

$$\nu_x \in [6.8897, 14.2695], \quad \nu_{x\mu} \in [0.7077, 4.6394].$$

因 $L = 1 \text{ pb}^{-1}$, 所以数值上

$$\sigma_x \in [6.8897, 14.2695] \text{ pb}, \quad \sigma_{x\mu} \in [0.7077, 4.6394] \text{ pb}.$$

- (2) 与 $\pm 1\sigma$ 比较

泊松大样本近似给出

$$10 \pm \sqrt{10} = [6.84, 13.16], \quad 2 \pm \sqrt{2} = [0.586, 3.414].$$

对 $n = 10$ 尚可, 对 $n = 2$ 则明显过于对称且上端偏低。

- (3) 第二个实验只测高 x 总数

若另一个实验亮度为 $L' = 100 \text{ pb}^{-1}$, 观测到 n'_x 个高 x 事例且不能识别 μ , 则可写联合似然

$$L(\sigma_x, p) = \text{Pois}(n_x | \sigma_x L) \text{Binom}(n_{x\mu} | n_x, p) \text{Pois}(n'_x | \sigma_x L'),$$

其中 $p = \sigma_{x\mu}/\sigma_x$ 。与 p 有关的项只有

$$n_{x\mu} \log p + (n_x - n_{x\mu}) \log(1 - p),$$

故

$$\hat{p} = \frac{n_{x\mu}}{n_x},$$

与 n'_x 无关。在这个条件二项模型下, 第二个实验确实不改变 p 的剖面似然形状; 它主要改善 σ_x 的估计。若存在共同系统误差或采用不同的无条件参数化, 结论才可能改变。

(4) 第一个实验只测到 $n_{x\mu}$

若原实验没有测 n_x , 只有 $n_{x\mu}$, 再结合第二个实验的 n'_x , 则联合似然为

$$L(\sigma_x, p) = \text{Pois}(n_{x\mu} | p\sigma_x L) \text{Pois}(n'_x | \sigma_x L').$$

对数似然为

$$\ell = n_{x\mu} \log(p\sigma_x L) - p\sigma_x L + n'_x \log(\sigma_x L') - \sigma_x L' + \text{const.}$$

若内部极值满足 $0 < \hat{p} < 1$, 解得

$$\hat{\sigma}_x = \frac{n'_x}{L'}, \quad \hat{p} = \frac{n_{x\mu} L'}{L n'_x}.$$

若该 $\hat{p} > 1$, 最大值会落在物理边界 $p = 1$ 。

用误差传播近似,

$$\hat{p} = \frac{L'}{L} \frac{n_{x\mu}}{n'_x},$$

因此

$$\sigma_{\hat{p}} \approx \hat{p} \sqrt{\frac{1}{n_{x\mu}} + \frac{1}{n'_x}}.$$

若以 $n'_x \approx 1000$ 作为与 $n_x = 10, L' = 100L$ 相容的例子, 则 $\hat{p} = 0.2$,

$$\sigma_{\hat{p}} \approx 0.2 \sqrt{\frac{1}{2} + \frac{1}{1000}} = 0.1416.$$

这个无条件模型给出的近似区间与 9.5 的二项精确区间不同, 因为它没有条件在固定的 $n_x = 10$ 上, 而是用另一个实验估计高 x 总率。

7. 相互作用中产生的某粒子以相对于 z 的某一角度发射出来, 如图 9.1 所示。探测器放在距离相互作用顶点为 d 处测量粒子垂直于 z 方向的位置 x 。角度 θ 定义为 z 轴与粒子径迹在 (x, z) 平面上投影的夹角。假设测量值 x 可以看做以真值为中心值, 标准偏差为 σ_x 的高斯变量。




图 9.1: 探测器测量 x 并由几何关系确定散射角 θ 的示意图。

- (1) 求 $\cos \theta$ 置信水平为 $1 - \gamma$ 的中心置信区间。

- (2) 取 $d = 1 \text{ m}$, $\sigma_x = 1 \text{ mm}$, 并假设测量值为 $x = 2.0 \text{ mm}$ 。求 $\cos \theta$ 置信水平分别为 68.3% 和 95% 的中心置信区间。

解答：

几何关系为

$$\tan \theta = \frac{x}{d}, \quad c \equiv \cos \theta = \frac{d}{\sqrt{d^2 + x^2}}.$$

测量值 $\hat{x}$ 的中心置信区间为

$$[x_-, x_+] = [\hat{x} - z_{1-\gamma/2}\sigma_x, \hat{x} + z_{1-\gamma/2}\sigma_x].$$

若整个区间在 $x \geq 0$ 或 $x \leq 0$ 的同一侧, 则 $c(x)$ 随 $|x|$ 单调下降, 因此可直接把端点变换为

$$c \in \left[\frac{d}{\sqrt{d^2 + x_+^2}}, \frac{d}{\sqrt{d^2 + x_-^2}} \right] \quad (x_- > 0).$$

如果区间跨过 $x = 0$, 上端应取 $c = 1$, 下端由端点中较大的 $|x|$ 给出。

题中

$$d = 1 \text{ m} = 1000 \text{ mm}, \quad \sigma_x = 1 \text{ mm}, \quad \hat{x} = 2.0 \text{ mm}.$$


- 68.3% 中心区间近似取 $z = 1$: $x_- = 1 \text{ mm}$, $x_+ = 3 \text{ mm}$ 。因此

$$\cos \theta \in [0.999995500, 0.999999500].$$

- 95% 中心区间取 $z = 1.96$: $x_- = 0.04 \text{ mm}$, $x_+ = 3.96 \text{ mm}$ 。因此

$$\cos \theta \in [0.999992159, 0.999999999].$$

由于 $x \ll d$, 角度很小, $\cos \theta$ 的区间自然非常靠近 1。



由 x 的中心置信区间通过单调变换得到 $\cos \theta$ 的区间。

实验物理中的统计方法

第 10 章特征函数

1. 证明高斯分布

$$f(x; \mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp \left[-\frac{(x - \mu)^2}{2\sigma^2} \right]$$

的特征函数为

$$\phi(k) = \exp \left(i\mu k - \frac{1}{2}\sigma^2 k^2 \right).$$

解答：

设

$$f(x; \mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma}} \exp \left[-\frac{(x - \mu)^2}{2\sigma^2} \right].$$

则

$$\phi(k) = \int_{-\infty}^{\infty} e^{ikx} f(x; \mu, \sigma^2) dx.$$

把指数配方：

$$ikx - \frac{(x - \mu)^2}{2\sigma^2} = -\frac{(x - \mu - i\sigma^2 k)^2}{2\sigma^2} + ik\mu - \frac{1}{2}\sigma^2 k^2.$$

因此高斯积分部分仍为 1，得到

$$\phi(k) = \exp \left(ik\mu - \frac{1}{2}\sigma^2 k^2 \right).$$

2. 证明指数分布

$$f(x; \xi) = \frac{1}{\xi} e^{-x/\xi}$$

的特征函数为

$$\phi(k) = \frac{1}{1 - ik\xi}.$$

解答：

设

$$f(x; \xi) = \frac{1}{\xi} e^{-x/\xi}, \quad x \geq 0.$$

则

$$\phi(k) = \int_0^{\infty} e^{ikx} \frac{1}{\xi} e^{-x/\xi} dx = \frac{1}{\xi} \int_0^{\infty} e^{-x(1/\xi - ik)} dx.$$

只要 $\text{Re}(1/\xi - ik) = 1/\xi > 0$ ，积分收敛，故

$$\phi(k) = \frac{1}{\xi} \cdot \frac{1}{1/\xi - ik} = \frac{1}{1 - ik\xi}.$$

3. 证明自由度为 n 的 χ^2 分布

$$f(z; n) = \frac{1}{2^{n/2}\Gamma(n/2)} z^{n/2-1} e^{-z/2}$$

的特征函数为

$$\phi(k) = (1 - 2ik)^{-n/2}.$$

提示：证明中需要用到伽马函数，定义为

$$\Gamma(x) = \int_0^\infty e^{-t} t^{x-1} dt.$$

解答：

若 $Z \sim \chi_n^2$ ，其密度为

$$f(z; n) = \frac{1}{2^{n/2}\Gamma(n/2)} z^{n/2-1} e^{-z/2}, \quad z > 0.$$

则

$$\phi(k) = \frac{1}{2^{n/2}\Gamma(n/2)} \int_0^\infty z^{n/2-1} e^{-z(1/2-ik)} dz.$$

利用伽马积分

$$\int_0^\infty z^{a-1} e^{-bz} dz = \frac{\Gamma(a)}{b^a},$$

得

$$\phi(k) = \frac{1}{2^{n/2}} \frac{1}{(1/2 - ik)^{n/2}} = (1 - 2ik)^{-n/2}.$$

故

$$\phi_{\chi_n^2}(k) = (1 - 2ik)^{-n/2}.$$

4. 假定随机变量 $x_1, \dots, x_n$ 相互独立，且都服从均值为 μ 、方差为 σ^2 的高斯分布。第 5 章和第 6 章给出，可以用样本均值

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

作为均值 μ 的估计量。

- (1) 求样本均值的特征函数。
- (2) 利用特征函数证明 $\bar{x}$ 服从高斯分布，并求其均值和方差。

解答：

设 $x_1, \dots, x_n$ 独立同分布，且

$$x_i \sim N(\mu, \sigma^2), \quad \bar{x} = \frac{1}{n} \sum_{i=1}^n x_i.$$

由独立性，

$$\phi_{\bar{x}}(k) = E\left[\exp\left(ik\frac{1}{n}\sum_i x_i\right)\right] = \prod_{i=1}^n \phi_{x_i}(k/n).$$

代入 10.1 的结果:

$$\phi_{\bar{x}}(k) = \left[\exp\left(i\mu\frac{k}{n} - \frac{1}{2}\sigma^2\frac{k^2}{n^2}\right)\right]^n = \exp\left(ik\mu - \frac{1}{2}\frac{\sigma^2}{n}k^2\right).$$

这正是高斯分布 $N(\mu, \sigma^2/n)$ 的特征函数, 所以

$$\bar{x} \sim N\left(\mu, \frac{\sigma^2}{n}\right).$$

5. 利用特征函数证明高斯分布的前 4 阶代数矩为

$$\begin{aligned} E[x] &= \mu, \\ E[x^2] &= \mu^2 + \sigma^2, \\ E[x^3] &= \mu^3 + 3\mu\sigma^2, \\ E[x^4] &= 3(\mu^2 + \sigma^2)^2 - 2\mu^4. \end{aligned}$$

解答:

由

$$\phi(k) = \exp\left(ik\mu - \frac{1}{2}\sigma^2k^2\right)$$

在 $k=0$ 展开, 或者直接使用

$$E[X^m] = \frac{1}{i^m} \frac{d^m \phi}{dk^m} \Big|_{k=0},$$

可得

$$\begin{aligned} E[X] &= \mu, \\ E[X^2] &= \mu^2 + \sigma^2, \\ E[X^3] &= \mu^3 + 3\mu\sigma^2, \\ E[X^4] &= \mu^4 + 6\mu^2\sigma^2 + 3\sigma^4 = 3(\mu^2 + \sigma^2)^2 - 2\mu^4. \end{aligned}$$

故书上给出的结果成立。

6.

- (1) 利用特征函数证明自由度为 n 的 χ^2 分布的均值和方差分别为 n 和 $2n$ 。
- (2) 假设 z 服从自由度为 n 的 χ^2 分布。证明: 在大 n 极限下, χ^2 分布变为均值为 $\mu = n$ 、方差为 $\sigma^2 = 2n$ 的高斯分布。提示: 证明中需要定义变量

$$y = \frac{z - n}{\sqrt{2n}},$$

y 的均值为零, 标准差为 1。证明 y 的特征函数为

$$\phi_y(k) = e^{-ik\sqrt{n/2}}\phi_z\left(\frac{k}{\sqrt{2n}}\right).$$

将 $\phi_y(k)$ 的对数展开, 并只保留大 n 极限下不消失的项, 然后再变换回变量 z 得到要证明的结果。

解答:

- (1) 均值与方差
由

$$\phi(k) = (1 - 2ik)^{-n/2}$$

取对数:

$$\log \phi(k) = -\frac{n}{2} \log(1 - 2ik).$$

也可直接求矩母函数 $M(t) = (1 - 2t)^{-n/2}$ 。于是

$$E[Z] = M'(0) = n, \quad \text{Var}(Z) = M''(0) - M'(0)^2 = 2n.$$

故

$$E[Z] = n, \quad \text{Var}(Z) = 2n.$$

- (2) 渐近高斯性
定义标准化变量

$$Y = \frac{Z - n}{\sqrt{2n}}.$$

则其特征函数为

$$\phi_Y(k) = e^{-ik\sqrt{n/2}} \phi_Z\left(\frac{k}{\sqrt{2n}}\right) = e^{-ik\sqrt{n/2}} \left(1 - \frac{2ik}{\sqrt{2n}}\right)^{-n/2}.$$

取对数并在 $n \rightarrow \infty$ 下展开:

$$\log \phi_Y(k) = -ik\sqrt{\frac{n}{2}} - \frac{n}{2} \log\left(1 - \frac{\sqrt{2}ik}{\sqrt{n}}\right) \rightarrow -\frac{1}{2}k^2.$$

故

$$\phi_Y(k) \rightarrow e^{-k^2/2},$$

这就是标准正态分布的特征函数, 因此

$$\frac{Z - n}{\sqrt{2n}} \xrightarrow[n \rightarrow \infty]{d} N(0, 1).$$

7. 假设 n 个相互独立的随机变量 $x_1, \dots, x_n$ 都服从标准高斯分布, 即对所有 $i = 1, \dots, n$,

$$\phi(x_i) = \frac{1}{\sqrt{2\pi}} e^{-x_i^2/2}.$$

考虑下面这个变量的性质:

$$y = \left(\sum_{i=1}^n x_i^2 \right)^{1/2}.$$

- (1) 首先只考虑某一个 x_i 。通过变量变换, 证明 $u = x_i^2$ 的概率密度函数为

$$f(u) = \frac{1}{\sqrt{2\pi u}} e^{-u/2}.$$

这是自由度为 1 的 χ^2 分布。

- (2) 证明 u 的特征函数为

$$\phi_u(k) = \frac{1}{\sqrt{1-2ik}}.$$

(3) 利用相加定理, 求下面变量的特征函数

$$v = \sum_{i=1}^n x_i^2.$$

(4) 利用变量变换, 证明 $y = (\sum_{i=1}^n x_i^2)^{1/2}$ 的概率密度函数为

$$h(y) = \frac{1}{2^{n/2-1}\Gamma(n/2)} y^{n-1} e^{-y^2/2}.$$

(5) 写出 $n=3$ 时的概率密度函数。这是 Maxwell-Boltzmann 分布。假设气体中分子的速度分量 v_x, v_y 和 v_z 都服从均值为零、标准差为 σ 的高斯分布。写出分子速度 $v = (v_x^2 + v_y^2 + v_z^2)^{1/2}$ 的概率密度函数。

(6) 写出 $n=1$ 时的概率密度函数。即, 如果 x 服从标准高斯分布, 则 $y = |x|$ 的概率密度函数是什么?

解答:

设 $x_i \sim N(0, 1)$ 相互独立。

(1) 令 $u = x_i^2$ 。由两个反函数分支 $x_i = \pm\sqrt{u}$ 得

$$f_U(u) = \frac{1}{\sqrt{2\pi u}} e^{-u/2}, \quad u > 0,$$

这就是自由度为 1 的 χ^2 分布。

(2) 因此

$$\phi_u(k) = E(e^{iku}) = (1 - 2ik)^{-1/2}.$$

(3) 令 $v = \sum_{i=1}^n x_i^2$ 。由独立性,

$$\phi_v(k) = \prod_{i=1}^n \phi_u(k) = (1 - 2ik)^{-n/2},$$

所以 $v \sim \chi_n^2$ 。

(4) 因 $y = \sqrt{v}$, 即 $v = y^2$, 有 $dv/dy = 2y$ 。于是

$$h(y) = f_v(y^2) 2y = \frac{1}{2^{n/2-1}\Gamma(n/2)} y^{n-1} e^{-y^2/2}, \quad y > 0.$$

(5) 当 $n=3$ 时,

$$h(y) = \sqrt{\frac{2}{\pi}} y^2 e^{-y^2/2}, \quad y > 0.$$

若速度分量 $v_x, v_y, v_z \sim N(0, \sigma^2)$, 则速率 r 的密度为

$$f(r) = \sqrt{\frac{2}{\pi}} \frac{r^2}{\sigma^3} e^{-r^2/(2\sigma^2)}, \quad r > 0.$$

(6) 当 $n=1$ 时,

$$h(y) = \sqrt{\frac{2}{\pi}} e^{-y^2/2}, \quad y > 0.$$

一般地, 若 $x \sim N(0, \sigma^2)$ 且 $y = |x|$, 则

$$h(y) = \sqrt{\frac{2}{\pi}} \frac{1}{\sigma} e^{-y^2/(2\sigma^2)}, \quad y > 0.$$

8. 考虑服从柯西分布的随机变量 x ,

$$f(x) = \frac{1}{\pi} \frac{1}{1+x^2}.$$

(1) 证明其特征函数为

$$\phi(k) = e^{-|k|}.$$

(利用留数定理, $k > 0$ 时选取上半平面的路径, $k < 0$ 时选取下半平面的路径。)

(2) 考虑柯西随机变量 x 的某个样本, 样本容量为 n 。利用 (a) 中得到的特征函数并应用相加定理, 证明样本均值 $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$ 也服从柯西分布。这是一个特例, 即 $\bar{x}$ 的概率密度函数不随样本容量的增加而改变, 这与柯西分布的各阶矩不存在有关。

解答:

设

$$f(x) = \frac{1}{\pi(1+x^2)}.$$

(1) 特征函数
计算

$$\phi(k) = \int_{-\infty}^{\infty} \frac{e^{ikx}}{\pi(1+x^2)} dx.$$

利用留数定理: 当 $k > 0$ 时取上半平面闭路, 包围极点 $x = i$; 当 $k < 0$ 时取下半平面闭路, 包围极点 $x = -i$ 。两种情形都得到

$$\phi(k) = e^{-|k|}.$$

(2) 样本均值仍服从柯西分布
若 $x_1, \dots, x_n$ 独立同分布为柯西, 则

$$\phi_{\bar{x}}(k) = \prod_{i=1}^n \phi_{x_i}(k/n) = \left(e^{-|k|/n}\right)^n = e^{-|k|}.$$

因此 $\bar{x}$ 与原变量同分布, 仍是柯西分布。这解释了为什么柯西分布没有通常意义上的大数定律行为。

9. 狄拉克 δ 函数

$$f(x; \mu) = \delta(x - \mu)$$

定义为

$$\delta(x - \mu) = 0, \quad x \neq \mu,$$

$$\int_{-\infty}^{\infty} \delta(x - \mu) dx = 1.$$

即, $\delta(x - \mu)$ 在 $x = \mu$ 处为无限尖锐的峰, 但在其它地方都等于零。求 $\delta(x - \mu)$ 的特征函数, 并据此得到 δ 函数的积分表示。

解答:

$$f(x; \mu) = \delta(x - \mu).$$

其特征函数直接为

$$\phi(k) = \int_{-\infty}^{\infty} e^{ikx} \delta(x - \mu) \, dx = e^{ik\mu}.$$

反过来，由傅里叶反演公式，

$$\delta(x - \mu) = \frac{1}{2\pi} \int_{-\infty}^{\infty} e^{-ik\mu} e^{ikx} \, dk = \frac{1}{2\pi} \int_{-\infty}^{\infty} e^{ik(x-\mu)} \, dk.$$

这就是 δ 函数的积分表示。

实验物理中的统计方法

第 11 章解谱法

1. 考虑图 9.1 的探测器设备。假设 x 的分辨率函数服从高斯分布

$$s(x|x') = \frac{1}{\sqrt{2\pi}\sigma_x} \exp\left[-\frac{(x-x')^2}{2\sigma_x^2}\right].$$

求 $\cos\theta = a/\sqrt{x^2 + a^2}$ 的分辨率函数。

解答：

记

$$c = \cos\theta = \frac{a}{\sqrt{x^2 + a^2}}, \quad 0 < c \leq 1.$$

由于这个变换依赖于 x^2 ，一般不是一一对应的。对给定 c ，反解为

$$x_{\pm}(c) = \pm a \frac{\sqrt{1-c^2}}{c}.$$

并且

$$\left| \frac{dx_{\pm}}{dc} \right| = \frac{a}{c^2 \sqrt{1-c^2}}.$$

若 x 是可正可负的测量坐标，则测得的 c 在真值 x' 下的分辨率函数应对两个分支求和：

$$\begin{aligned} s_c(c|x') &= \sum_{\epsilon=\pm 1} s\left(\epsilon a \frac{\sqrt{1-c^2}}{c} \middle| x'\right) \frac{a}{c^2 \sqrt{1-c^2}} \\ &= \frac{a}{c^2 \sqrt{1-c^2}} \frac{1}{\sqrt{2\pi}\sigma_x} \left\{ \exp\left[-\frac{(x_+(c)-x')^2}{2\sigma_x^2}\right] + \exp\left[-\frac{(x_-(c)-x')^2}{2\sigma_x^2}\right] \right\}. \end{aligned}$$


其中 $0 < c \leq 1$ 。

若问题物理上只允许 $x \geq 0$ 的单支（例如 x 表示非负距离），则只保留正分支：

$$s_c(c|c') = \frac{1}{\sqrt{2\pi}\sigma_x} \exp\left[-\frac{(x(c)-x(c'))^2}{2\sigma_x^2}\right] \frac{a}{c^2 \sqrt{1-c^2}},$$

其中

$$x(c) = a \frac{\sqrt{1-c^2}}{c}.$$



单支 $x \geq 0$ 情形下，非线性变换后 $c = \cos\theta$ 分辨率函数的示例。

2. 对等区间宽度的直方图 $\mu = (\mu_1, \dots, \mu_M)$, 考虑 $k = 1$ 的 Tikhonov 正规化函数,

$$S(\mu) = - \sum_{i=1}^{M-1} (\mu_i - \mu_{i+1})^2.$$

求 $M \times M$ 维矩阵 G , 使得 $S(\mu)$ 可以表示成以下形式

$$S(\mu) = - \sum_{i,j=1}^M G_{ij} \mu_i \mu_j = -\mu^T G \mu.$$

解答:

展开平方和:

$$\sum_{i=1}^{M-1} (\mu_i - \mu_{i+1})^2 = \mu_1^2 + \mu_M^2 + 2 \sum_{i=2}^{M-1} \mu_i^2 - 2 \sum_{i=1}^{M-1} \mu_i \mu_{i+1}.$$


因此 $S(\mu) = -\mu^T G \mu$, 其中

$$G = \begin{pmatrix} 1 & -1 & 0 & \cdots & 0 \\ -1 & 2 & -1 & \ddots & \vdots \\ 0 & -1 & 2 & \ddots & 0 \\ \vdots & \ddots & \ddots & 2 & -1 \\ 0 & \cdots & 0 & -1 & 1 \end{pmatrix}.$$

等价地,

$$G_{11} = G_{MM} = 1, \quad G_{ii} = 2 \quad (2 \leq i \leq M-1), \quad G_{i,i+1} = G_{i+1,i} = -1,$$

其余矩阵元为 0。这就是离散一阶差分平方对应的二次型矩阵。



$M = 8$ 时一阶 Tikhonov 矩阵 G 的结构示意。

3. 考虑期待值为 $\mu = (\mu_1, \dots, \mu_M)$ 的直方图, 对应的概率为 $p = \mu/\mu_{\text{tot}}$, 其中 $\mu_{\text{tot}} = \sum_{i=1}^M \mu_i$ 。

(1) 证明 Shannon 熵

$$H(p) = - \sum_{i=1}^M p_i \log p_i,$$

在所有区间 i 的 $p_i = 1/M$ 时最大。(利用 Lagrange 乘子法引入限制条件 $\sum_{i=1}^M p_i = 1$ 。)

(2) 证明交叉熵

$$K(p; q) = - \sum_{i=1}^M p_i \log \frac{p_i}{M q_i},$$

在概率 p 等于参考分布 q 时最大。

解答:

设 $p_i = \mu_i / \mu_{\text{tot}}$, 于是 $\sum_i p_i = 1$ 。

(1) 在约束 $\sum_i p_i = 1$ 下, 对 Shannon 熵

$$H(\mathbf{p}) = - \sum_{i=1}^M p_i \log p_i$$

作 Lagrange 乘子法:

$$L(\mathbf{p}, \lambda) = - \sum_i p_i \log p_i + \lambda \left(\sum_i p_i - 1 \right).$$

由

$$\frac{\partial L}{\partial p_i} = -(\log p_i + 1) + \lambda = 0$$

可知所有 p_i 相等。结合归一化条件, 得到

$$p_i = \frac{1}{M}, \quad H_{\max} = \log M.$$

(2) 将题中的量改写为

$$K(\mathbf{p}; \mathbf{q}) = - \sum_{i=1}^M p_i \log \frac{p_i}{M q_i} = \log M - \sum_{i=1}^M p_i \log \frac{p_i}{q_i} = \log M - D_{\text{KL}}(\mathbf{p} \| \mathbf{q}).$$

由于 $D_{\text{KL}}(\mathbf{p} \| \mathbf{q}) \geq 0$, 且等号仅在 $\mathbf{p} = \mathbf{q}$ 时成立, 所以

$$K(\mathbf{p}; \mathbf{q}) \leq \log M.$$

因此 K 在 $p = q$ 时达到最大值。

4. 考虑观测到的直方图 $n = (n_1, \dots, n_N)$, 对应的期待值 $\nu = (\nu_1, \dots, \nu_N)$ 与真值直方图 $\mu = (\mu_1, \dots, \mu_N)$ 的关系为 $\nu = R\mu$ 。假设协方差矩阵 V 和响应矩阵 R 已知, 并且直方图中没有本底。

(1) 通过最大化 $\Phi(\mu)$ 构造 μ 的估计量

$$\begin{aligned} \Phi(\mu) &= -\frac{\alpha}{2} \chi^2(\mu) + S(\mu) \\ &= -\frac{\alpha}{2} (n - R\mu)^T V^{-1} (n - R\mu) - \mu^T G \mu, \end{aligned}$$

其中 α 为正规化参数, $M \times M$ 对称矩阵 G 由已知常数确定 (参考 Statistical Data Analysis 中 11.5.1 节)。证明估计量 $\hat{\mu}$ 为

$$\hat{\mu} = (\alpha R^T V^{-1} R + 2G)^{-1} \alpha R^T V^{-1} n,$$

并求协方差矩阵 $U_{ij} = \text{cov}[\hat{\mu}_i, \hat{\mu}_j]$ 。

- (2) 考虑限制条件 $\nu_{\text{tot}} = \sum_{i=1}^N \nu_i = \sum_{i=1}^N \sum_{j=1}^M R_{ij} \mu_j$ 等于总观测事例数 $n_{\text{tot}} = \sum_{i=1}^N n_i$, 通过对参数 μ 和 Lagrange 乘子 λ 最大化 $\phi(\mu)$ 求得结果

$$\phi(\mu) = -\frac{\alpha}{2}(n - R\mu)^T V^{-1}(n - R\mu) - \mu^T G\mu + \lambda(n_{\text{tot}} - \nu_{\text{tot}}).$$

求估计量 $\hat{\mu}$ 及其协方差。

- (3) 利用 Statistical Data Analysis 中方程 (11.76), 对 (a) 和 (b) 两种情况分别构造偏置 $b = E[\hat{\mu}] - \mu$ 的估计量 $\hat{b}$ 。

解答:

记

$$M = \alpha R^T V^{-1} R + 2G.$$

- (1) 无总数约束

对

$$\Phi(\mu) = -\frac{\alpha}{2}(n - R\mu)^T V^{-1}(n - R\mu) - \mu^T G\mu$$

求驻点:

$$\alpha R^T V^{-1}(n - R\hat{\mu}) - 2G\hat{\mu} = 0.$$

故

$$\hat{\mu} = M^{-1} \alpha R^T V^{-1} n.$$

令

$$A = M^{-1} \alpha R^T V^{-1},$$

则 $\hat{\mu} = An$ 。若 $\text{cov}(n) = V$, 则

$$U = \text{cov}(\hat{\mu}) = AVA^T = \alpha^2 M^{-1} R^T V^{-1} R M^{-1}.$$

- (2) 加总数约束

令 $\mathbf{1}_N$ 为 N 维全 1 向量,

$$c = R^T \mathbf{1}_N.$$

约束为

$$c^T \mu = \mathbf{1}_N^T n.$$

带 Lagrange 乘子的驻点方程为

$$M\hat{\mu} = \alpha R^T V^{-1} n + \lambda c.$$

先定义无约束线性解

$$\mu_0 = M^{-1} \alpha R^T V^{-1} n.$$

由约束得

$$\lambda = \frac{\mathbf{1}_N^T n - c^T \mu_0}{c^T M^{-1} c}.$$

所以

$$\hat{\mu} = \mu_0 + M^{-1} c \frac{\mathbf{1}_N^T n - c^T \mu_0}{c^T M^{-1} c}.$$

为避免排版歧义, 上式也可写成

$$\hat{\mu} = Bn,$$


其中

$$B = M^{-1} \alpha R^T V^{-1} + M^{-1} c \frac{\mathbf{1}_N^T - c^T M^{-1} \alpha R^T V^{-1}}{c^T M^{-1} c}.$$

于是

$$U_{\text{constr}} = BVB^T.$$

(3) 偏置估计



解谱问题中一个响应矩阵的示意；列归一化表示每个真值 bin 对观测 bin 的迁移概率。

若线性估计量写成 $\hat{\mu} = An$ ，且 $E[n] = R\mu$ ，则

$$b = E[\hat{\mu}] - \mu = (AR - I)\mu.$$

实际中 μ 未知，按书中式 (11.76) 的思想可用估计量代入，取

$$\hat{b} = (AR - I)\hat{\mu}.$$

无约束情形

$$A = M^{-1}\alpha R^T V^{-1},$$

并且利用 $M = \alpha R^T V^{-1} R + 2G$ ，有

$$AR - I = -2M^{-1}G,$$

因此

$$\hat{b}_a = -2M^{-1}G\hat{\mu}.$$

带约束情形只需把 A 换成 B ：

$$\hat{b}_b = (BR - I)\hat{\mu}.$$

若展开，可得

$$BR - I = -2M^{-1} \left(G - \frac{c c^T M^{-1} G}{c^T M^{-1} c} \right),$$

所以

$$\hat{b}_b = -2M^{-1} \left(G - \frac{c c^T M^{-1} G}{c^T M^{-1} c} \right) \hat{\mu}.$$